




دانشگاه صنعتی خواجه نصیرالدین طوسی
دانشکده مهندسی برق - گروه مهندسی کنترل

درس مبانی سیستم‌های هوشمند

پاسخ مینی پروژه دوم

FIS4041 - Mini Project 2

نام و نام خانوادگی	نیکی مهدیان
شماره دانشجویی	۴۰۱۲۳۱۵۳
تاریخ	آذرماه ۱۴۰۳

مخزن GitHub

<https://github.com/nikimahdian/Principles-of-Intelligent-Systems>



فهرست مطالب

۸	سوال اول: ماشین بردار پشتیبان سخت‌حاشیه، اثبات پهنای حاشیه، فرم دوگان	۱
۸	قسمت الف: صورت‌بندی مسئله بهینه‌سازی اولیه	۱.۱
۸	مقدمه و انگیزه	۱.۱.۱
۸	تعریف ابرصفحه جداکننده	۲.۱.۱
۸	شرایط طبقه‌بندی صحیح	۳.۱.۱
۹	فرم فشرده قیود	۴.۱.۱
۹	فرمول‌بندی نهایی مسئله بهینه‌سازی	۵.۱.۱
۹	تحلیل مسئله	۶.۱.۱
۹	قسمت ب: برهان ریاضی فاصله حاشیه‌ای	۲.۱
۹	تعریف ابرصفحات مرزی (حاشیه‌ای)	۱.۲.۱
۱۰	روش اول: استفاده از فرمول فاصله نقطه تا صفحه	۲.۲.۱
۱۰	روش دوم: استفاده از تصویر بردار اتصال	۳.۲.۱
۱۰	تعریف حاشیه هندسی	۴.۲.۱
۱۱	نتیجه‌گیری	۵.۲.۱
۱۱	قسمت ج: استخراج فرم دوگان و تحلیل بردارهای پشتیبان	۳.۱
۱۱	چرا به فرم دوگان نیاز داریم؟	۱.۳.۱
۱۱	مرحله اول: تشکیل تابع لاگرانژی	۲.۳.۱
۱۲	مرحله دوم: شرایط ایستایی (نقطه زینی)	۳.۳.۱
۱۲	مرحله سوم: جایگزینی و استخراج تابع دوگان	۴.۳.۱
۱۳	مرحله چهارم: صورت‌بندی کامل مسئله دوگان	۵.۳.۱
۱۳	محاسبه بایاس b	۶.۳.۱
۱۳	شرایط KKT و بردارهای پشتیبان	۷.۳.۱
۱۴	تحلیل کامل سه حالت ممکن	۸.۳.۱
۱۴	تابع تصمیم‌گیری نهایی	۹.۳.۱
۱۴	مزایای تنکی جواب	۱۰.۳.۱
۱۵	سوال دوم: حاشیه نرم، متغیرهای کمکی و تابع زیان لولایی	۲
۱۵	قسمت الف: معرفی متغیرهای کمکی و فرم اولیه	۱.۲
۱۵	انگیزه: محدودیت‌های حاشیه سخت	۱.۱.۲
۱۵	راه‌حل: متغیرهای شل‌شدگی	۲.۱.۲
۱۵	تفسیر هندسی متغیرهای شل‌شدگی	۳.۱.۲
۱۶	فرمول‌بندی مسئله حاشیه نرم با نرم یک	۴.۱.۲
۱۶	تحلیل تابع هدف	۵.۱.۲
۱۶	نقش پارامتر تنظیم C	۶.۱.۲



۱۶	قسمت ب: برهان هم‌ارزی با تابع زیان لولایی	۲.۲
۱۶	هدف اثبات	۱.۲.۲
۱۷	گام اول: حذف قیود با جایگزینی	۲.۲.۲
۱۷	گام دوم: تحلیل موردی	۳.۲.۲
۱۷	گام سوم: تعریف تابع زیان لولایی	۴.۲.۲
۱۸	گام چهارم: فرم معادل نامحدود	۵.۲.۲
۱۸	ارتباط با چارچوب تنظیم‌شده	۶.۲.۲
۱۸	مقایسه با سایر توابع زیان	۷.۲.۲
۱۹	قسمت ج: بررسی اثر پارامتر C بر عملکرد مدل	۳.۲
۱۹	دیدگاه نظری: مصالحه بایاس-واریانس	۱.۳.۲
۱۹	تحلیل دقیق C بزرگ	۲.۳.۲
۲۰	تحلیل دقیق C کوچک	۳.۳.۲
۲۰	تاثیر بر تعداد بردارهای پشتیبان	۴.۳.۲
۲۱	جدول خلاصه تاثیرات	۵.۳.۲
۲۱	روش‌های انتخاب C بهینه	۶.۳.۲
۲۲	سوال سوم: جریمه مربعی، تفاوت با نرم یک، کرنل و شرایط KKT	۳
۲۲	قسمت الف: فرم اولیه با جریمه مربعی (نرم دو)	۱.۳
۲۲	انگیزه استفاده از جریمه مربعی	۱.۱.۳
۲۲	فرمول‌بندی مسئله اولیه	۲.۱.۳
۲۲	تفاوت‌های کلیدی با نرم یک	۳.۱.۳
۲۳	قسمت ب: استخراج فرم دوگان	۲.۳
۲۳	تشکیل تابع لاگرانژی	۱.۲.۳
۲۳	شرایط ایستایی	۲.۲.۳
۲۴	جایگزینی و ساده‌سازی	۳.۲.۳
۲۴	فرم دوگان نهایی	۴.۲.۳
۲۴	تفسیر: کرنل اصلاح‌شده	۵.۲.۳
۲۵	قسمت ج: مقایسه محدودیت‌های ضرایب لاگرانژ	۳.۳
۲۵	استخراج محدوده α_i در نرم یک	۱.۳.۳
۲۵	استخراج محدوده α_i در نرم دو	۲.۳.۳
۲۵	پیامدهای عملی تفاوت محدوده‌ها	۳.۳.۳
۲۶	جدول مقایسه کامل	۴.۳.۳
۲۶	کاربردهای هر روش	۵.۳.۳
۲۶	قسمت د: مفهوم کرنل معتبر و ترفند کرنل	۴.۳
۲۶	انگیزه: طبقه‌بندی غیرخطی	۱.۴.۳
۲۷	ترفند کرنل	۲.۴.۳



۲۷	تعریف رسمی کرنل معتبر	۳.۴.۳
۲۷	قضیه مرسر	۴.۴.۳
۲۷	مثال: کرنل چندجمله‌ای درجه ۲	۵.۴.۳
۲۸	قسمت ۵: اثبات اعتبار کرنل‌های متداول	۵.۳
۲۸	خواص بستاری کرنل‌ها	۱.۵.۳
۲۸	کرنل خطی	۲.۵.۳
۲۸	کرنل چندجمله‌ای	۳.۵.۳
۲۸	کرنل گاوسی (RBF)	۴.۵.۳
۲۹	ابعاد فضای ویژگی کرنل‌ها	۵.۵.۳
۲۹	قسمت ۶: شرایط KKT برای مدل نرم دو	۶.۳
۲۹	شرایط KKT برای مسئله نرم دو	۱.۶.۳
۳۰	تحلیل کامل حالات بر اساس شرایط KKT	۲.۶.۳
۳۰	خلاصه حالات در جدول	۳.۶.۳
۳۱	مقایسه با شرایط KKT در نرم یک	۴.۶.۳
۳۱	نتیجه‌گیری مهم	۵.۶.۳
۳۲	سوال پنجم: حل دستی SVM برای داده‌های دوبعدی	۴
۳۲	معرفی مسئله و داده‌ها	۱.۴
۳۲	قسمت الف: تحلیل هندسی و حدس مرز تصمیم	۲.۴
۳۲	بررسی توزیع داده‌ها	۱.۲.۴
۳۳	خواص تقارنی	۲.۲.۴
۳۳	استنتاج مرز بهینه	۳.۲.۴
۳۳	قسمت ب: محاسبه پارامترهای مدل	۳.۴
۳۳	شناسایی بردارهای پشتیبان احتمالی	۱.۳.۴
۳۳	تشکیل دستگاه معادلات	۲.۳.۴
۳۴	حل دستگاه معادلات	۳.۳.۴
۳۴	نتایج	۴.۳.۴
۳۵	قسمت ج: محاسبه حاشیه و تعیین بردارهای پشتیبان	۴.۴
۳۵	شناسایی دقیق بردارهای پشتیبان	۱.۴.۴
۳۵	محاسبه نرم بردار وزن	۲.۴.۴
۳۵	محاسبه حاشیه هندسی	۳.۴.۴
۳۶	محاسبه پهنای کل حاشیه	۴.۴.۴
۳۶	محاسبه فاصله نقاط مختلف	۵.۴.۴
۳۶	جدول خلاصه نتایج	۶.۴.۴



۳۷	سوال ششم: مقایسه شبکه‌های عصبی برای داده‌های خوشه‌ای	۵
۳۷	توصیف مسئله	۱.۵
۳۷	قسمت الف: پیشنهاد معماری مناسب	۲.۵
۳۷	انتخاب پیشنهادی	۱.۲.۵
۳۷	دلایل انتخاب شبکه RBF	۲.۲.۵
۳۸	معماری پیشنهادی شبکه RBF	۳.۲.۵
۳۸	گزینه‌های جایگزین	۴.۲.۵
۳۸	قسمت ب: تحلیل ضعف شبکه‌های پرسپترون چندلایه	۳.۵
۳۸	ساختار ریاضی شبکه MLP	۱.۳.۵
۳۸	مشکل اول: تقسیم سراسری فضا	۲.۳.۵
۳۹	مشکل دوم: برون‌یابی نامناسب (اطمینان کاذب)	۳.۳.۵
۳۹	مشکل سوم: عدم توانایی در تشخیص «نمی‌دانم»	۴.۳.۵
۳۹	تحلیل ریاضی برتری شبکه RBF	۵.۳.۵
۳۹	مقایسه رفتار در ناحیه مرکزی	۶.۳.۵
۴۰	جدول مقایسه جامع	۷.۳.۵
۴۰	نتیجه‌گیری	۸.۳.۵
۴۲	پیاپی سازی شبکه عصبی RBF	۶
۴۲	قسمت اول: شبکه RBFNN ایستا	۱.۶
۴۲	بخش اول: ایجاد دیتاست Ball and Beam	۱.۱.۶
۴۳	بخش دوم: پیاپی سازی RBFNN ایستا	۲.۱.۶
۴۸	بخش سوم: آموزش از طریق حداقل مربعات خطی (LLS)	۳.۱.۶
۵۳	بخش چهارم: تلاش برای حل چالش‌ها با L2 Regularization	۴.۱.۶
۵۵	بخش پنجم: استفاده از K-Means برای انتخاب مراکز	۵.۱.۶
۵۷	قسمت دوم: شبکه RBFNN تطبیقی با الهام از M-RAN	۲.۶
۵۷	بخش اول: یادگیری ترتیبی و معیار رشد	۱.۲.۶
۵۷	بخش دوم: پیاپی سازی RBFNN تطبیقی با هرس	۲.۲.۶
۶۱	سوال هفتم: SVM خطی و مطالعه پارامتر C	۷
۶۱	قسمت الف: آماده سازی داده	۱.۷
۶۲	قسمت ب: آموزش و گزارش حاشیه	۲.۷
۶۲	قسمت ج: مطالعه پارامتر C	۳.۷
۶۴	قسمت د: منحنی‌های ارزیابی	۴.۷



فهرست تصاویر

۴۳		سیگنال ورودی و خروجی سیستم Ball and Beam	۱
۴۴		تأثیر مرکز (μ) و عرض (σ) بر تابع فعال‌سازی RBF	۲
۴۵		نمایش سه‌بعدی و کانتور تابع فعال‌سازی RBF گوسی	۳
۴۶		مقایسه خروجی واقعی و پیش‌بینی شده توسط شبکه RBFNN	۴
۴۷		تأثیر تعداد نورون‌های مخفی بر معیارهای R^2 و RMSE	۵
۴۹		مقایسه خروجی واقعی و پیش‌بینی شده برای داده‌های آموزش و تست	۶
۵۰		تأثیر تعداد مراکز (K) بر RMSE	۷
۵۱		تأثیر عرض (σ) بر RMSE تست	۸
۵۲		خروجی بهترین مدل ($K = 200$, $\sigma = 10$) روی داده تست	۹
۵۳		تأثیر ضریب رگولاریزاسیون (λ) بر RMSE و R^2	۱۰
۵۴		مقایسه خروجی شبکه با و بدون L2 Regularization	۱۱
۵۵		مقایسه خروجی با مراکز K-Means و تصادفی	۱۲
۵۶		مقایسه σ ثابت و σ متغیر (Nearest-Neighbor)	۱۳
۵۸		نتایج RBFNN تطبیقی روی داده‌های تست	۱۴
۵۸		تغییر تعداد نورون‌ها در طول آموزش	۱۵
۵۹		مقایسه RBFNN تطبیقی و ایستا	۱۶
۶۱		نمایش PCA دوبعدی داده‌های آموزش	۱۷
۶۳		تحلیل تأثیر پارامتر C	۱۸
۶۴		منحنی‌های ROC و Precision-Recall برای $C = 1$	۱۹



فهرست جداول

۱۴		دسته‌بندی نمونه‌ها بر اساس مقدار α_i	۱
۱۵		تفسیر مقادیر مختلف ξ_i	۲
۱۸		مقایسه توابع زیان رایج در طبقه‌بندی دودویی	۳
۲۱		خلاصه تاثیر پارامتر C بر مشخصات مدل	۴
۲۲		مقایسه فرم‌بندی نرم یک و نرم دو	۵
۲۶		مقایسه جامع دو روش جریمه‌دهی	۶
۲۸		خواص بستاری کرنل‌های معتبر	۷
۲۹		ابعاد فضای ویژگی ضمنی	۸
۳۰		دسته‌بندی نمونه‌ها بر اساس شرایط KKT در نرم دو	۹
۳۱		مقایسه حالات KKT در دو مدل	۱۰
۳۲		داده‌های آموزشی	۱۱
۳۶		فاصله هر نقطه از مرز تصمیم	۱۲
۳۶		خلاصه نتایج محاسبات دستی SVM	۱۳
۳۹		رفتار توابع فعال‌سازی MLP در $ x \rightarrow \infty$	۱۴
۴۰		مقایسه جامع معماری‌های MLP و RBF	۱۵
۴۴		نتایج تست تابع RBF با $\mu = [1, 1]$ و $\sigma = 1$	۱۶
۴۵		معیارهای عملکرد شبکه RBFNN با $K = 25$ نورون	۱۷
۴۶		تأثیر تعداد نورون‌های مخفی (K) بر عملکرد شبکه	۱۸
۴۸		نتایج آموزش اولیه با $K = 25$ و $\sigma = 6.90$	۱۹
۴۹		تأثیر تعداد مراکز بر عملکرد (با σ ثابت)	۲۰
۵۱		تأثیر عرض بر عملکرد (با $K = 200$)	۲۱
۵۳		تأثیر ضریب رگولاریزاسیون (λ) بر عملکرد	۲۲
۵۵		مقایسه K-Means و انتخاب تصادفی ($K = 50$)	۲۳
۵۵		نتایج با σ متغیر (NN با $p = 2$)	۲۴
۵۸		جستجوی هایپر پارامتر ($M = 60$, $\delta = 0.1$, $\eta = 0.05$, $\kappa = 0.8$)	۲۵
۵۹		مقایسه مدل‌های مختلف	۲۶
۶۲		نتایج آموزش با $C = 1$	۲۷
۶۲		شاخص‌های عملکرد ($C = 1$)	۲۸
۶۲		تأثیر C بر عملکرد مدل	۲۹



فهرست برنامه‌ها



۱ سوال اول: ماشین بردار پشتیبان سخت‌حاشیه، اثبات پهنای حاشیه، فرم دوگان

۱.۱ قسمت الف: صورت‌بندی مسئله بهینه‌سازی اولیه

۱.۱.۱ مقدمه و انگیزه

ماشین بردار پشتیبان (Support Vector Machine - SVM) یکی از الگوریتم‌های قدرتمند یادگیری ماشین است که توسط ولادیمیر واپنیک در دهه ۱۹۹۰ معرفی شد. ایده اصلی این روش، یافتن ابرصفحه‌ای است که نه تنها داده‌های دو کلاس را از هم جدا کند، بلکه بیشترین فاصله ممکن را از نزدیک‌ترین نمونه‌های هر کلاس داشته باشد.

چرا بزرگ‌ترین حاشیه؟

بر اساس نظریه یادگیری آماری، مدلی که حاشیه بزرگ‌تری دارد، توانایی تعمیم بهتری خواهد داشت. این موضوع با کران‌های VC-dimension و حدود تعمیم قابل اثبات است. به زبان ساده، حاشیه بزرگ‌تر به معنای اطمینان بیشتر در طبقه‌بندی است.

۲.۱.۱ تعریف ابرصفحه جداکننده

یک ابرصفحه در فضای $\mathbb{R}^d$ با معادله زیر تعریف می‌شود:

$$\mathcal{H} : w^T x + b = 0 \quad (1)$$

که در آن:

- $w \in \mathbb{R}^d$ بردار وزن و عمود بر ابرصفحه است
- $b \in \mathbb{R}$ مقدار بایاس (عرض از مبدا) است که فاصله صفحه از مبدا را کنترل می‌کند
- $x \in \mathbb{R}^d$ بردار ویژگی ورودی است

۳.۱.۱ شرایط طبقه‌بندی صحیح

فرض کنید مجموعه آموزشی شامل N نمونه به صورت $\{(x_i, y_i)\}_{i=1}^N$ باشد که $y_i \in \{-1, +1\}$ برچسب کلاس است. برای آنکه ابرصفحه همه نمونه‌ها را صحیح جدا کند:

برای کلاس مثبت $(y_i = +1)$:

$$w^T x_i + b > 0$$

برای کلاس منفی $(y_i = -1)$:

$$w^T x_i + b < 0$$

اما این شرایط ضعیف هستند. ما می‌خواهیم حداقل فاصله‌ای تضمین شود. با نرمال‌سازی مناسب، می‌توانیم خواستار شویم:

• نمونه‌های کلاس مثبت: $w^T x_i + b \geq +1$

• نمونه‌های کلاس منفی: $w^T x_i + b \leq -1$



۴.۱.۱ فرم فشرده قیود

با ترکیب دو شرط بالا در یک نامعادله واحد:

$$y_i(w^T x_i + b) \geq 1, \quad \forall i \in \{1, 2, \dots, N\} \quad (۲)$$

توضیح: وقتی $y_i = +1$ ، این رابطه به $w^T x_i + b \geq 1$ تبدیل می‌شود. وقتی $y_i = -1$ ، با ضرب در -1 ، به $w^T x_i + b \leq -1$ می‌رسیم.

۵.۱.۱ فرمول‌بندی نهایی مسئله بهینه‌سازی

هدف ما بهینه‌سازی حاشیه است. همان‌طور که در بخش بعدی ثابت خواهیم کرد، پهنای حاشیه برابر $\frac{2}{\|w\|}$ است. بنابراین بهینه‌سازی حاشیه معادل کمینه‌سازی $\|w\|$ یا به طور معادل $\frac{1}{2}\|w\|^2$ است:

$$\begin{array}{ll} \underset{w \in \mathbb{R}^d, b \in \mathbb{R}}{\text{minimize}} & \frac{1}{2}\|w\|^2 \\ \text{to subject} & y_i(w^T x_i + b) \geq 1, \quad \forall i \in \{1, \dots, N\} \end{array} \quad (۳)$$

۶.۱.۱ تحلیل مسئله

نوع مسئله: این یک برنامه‌ریزی درجه دوم محدب (Convex Quadratic Programming) است. تابع هدف $\frac{1}{2}\|w\|^2 = \frac{1}{2}w^T w$ کاملاً محدب است و قیود خطی هستند، لذا مسئله دارای جواب یکتا است.

چرا $\frac{1}{2}$ ؟ ضرب $\frac{1}{2}$ صرفاً برای سادگی در مشتق‌گیری اضافه شده و تاثیری بر جواب بهینه ندارد. پیش‌فرض کلیدی: داده‌ها باید به صورت خطی جداپذیر باشند، یعنی حداقل یک ابرصفحه وجود داشته باشد که دو کلاس را کاملاً از هم جدا کند. اگر این شرط برقرار نباشد، مسئله infeasible خواهد بود. پیچیدگی محاسباتی: حل این مسئله با الگوریتم‌های بهینه‌سازی استاندارد مانند SMO یا Interior Point Methods امکان‌پذیر است.

۲.۱ قسمت ب: برهان ریاضی فاصله حاشیه‌ای

در این بخش با دروش مختلف اثبات می‌کنیم که پهنای حاشیه برابر $\frac{2}{\|w\|}$ است.

۱.۲.۱ تعریف ابرصفحات مرزی (حاشیه‌ای)

سه ابرصفحه موازی داریم:

$$H_0 : w^T x + b = 0 \quad (\text{ابرفصله تصمیم}) \quad (۴)$$

$$H_+ : w^T x + b = +1 \quad (\text{مرز کلاس مثبت}) \quad (۵)$$

$$H_- : w^T x + b = -1 \quad (\text{مرز کلاس منفی}) \quad (۶)$$

بردارهای پشتیبان، نقاطی هستند که دقیقاً روی H_+ یا H_- قرار دارند.



۲.۲.۱ روش اول: استفاده از فرمول فاصله نقطه تا صفحه

فاصله هر نقطه x_0 از ابرصفحه $w^T x + b = 0$ برابر است با:

$$d(x_0, H_0) = \frac{|w^T x_0 + b|}{\|w\|} \quad (۷)$$

فاصله بردار پشتیبان مثبت از مرز تصمیم:

برای x_+ روی H_+ داریم $w^T x_+ + b = 1$ پس:

$$d_+ = \frac{|1|}{\|w\|} = \frac{1}{\|w\|}$$

فاصله بردار پشتیبان منفی از مرز تصمیم:

برای x_- روی H_- داریم $w^T x_- + b = -1$ پس:

$$d_- = \frac{|-1|}{\|w\|} = \frac{1}{\|w\|}$$

پهنای کل حاشیه:

$$\gamma = d_+ + d_- = \frac{1}{\|w\|} + \frac{1}{\|w\|} = \frac{2}{\|w\|} \quad (۸)$$

۳.۲.۱ روش دوم: استفاده از تصویر بردار اتصال

فرض کنید x_+ نقطه‌ای روی H_+ و x_- نقطه‌ای روی H_- باشد. بردار اتصال این دو نقطه $x_+ - x_-$ است. فاصله عمودی دو صفحه برابر است با تصویر این بردار روی راستای عمود (یعنی راستای w):

$$\gamma = (x_+ - x_-) \cdot \hat{w} = (x_+ - x_-) \cdot \frac{w}{\|w\|} \quad (۹)$$

گام اول: از معادله H_+ داریم $w^T x_+ + b = 1$ پس $w^T x_+ = 1 - b$

گام دوم: از معادله H_- داریم $w^T x_- + b = -1$ پس $w^T x_- = -1 - b$

گام سوم: محاسبه فاصله:

$$\begin{aligned} \gamma &= \frac{w^T (x_+ - x_-)}{\|w\|} = \frac{w^T x_+ - w^T x_-}{\|w\|} \\ &= \frac{(1 - b) - (-1 - b)}{\|w\|} = \frac{1 - b + 1 + b}{\|w\|} = \frac{2}{\|w\|} \end{aligned} \quad (۱۰)$$

۴.۲.۱ تعریف حاشیه هندسی

حاشیه هندسی یک نمونه x_i به صورت زیر تعریف می‌شود:

$$\gamma_i = \frac{y_i (w^T x_i + b)}{\|w\|} \quad (۱۱)$$

این مقدار فاصله علامت‌دار نمونه از مرز تصمیم است. برای نمونه‌های صحیح طبقه‌بندی شده، $\gamma_i > 0$.

حاشیه مجموعه داده:

$$\gamma = \min_i \gamma_i$$



۵.۲.۱ نتیجه‌گیری

$$\boxed{\frac{2}{\|w\|} = \text{پهنای حاشیه}} \quad (۱۲)$$

ارتباط با تابع هدف:

بیشینه‌سازی حاشیه $\frac{2}{\|w\|}$ معادل است با:

$$\max_w \frac{2}{\|w\|} \Leftrightarrow \min_w \|w\| \Leftrightarrow \min_w \frac{1}{2} \|w\|^2$$

لذا کمینه‌سازی $\frac{1}{2} \|w\|^2$ در تابع هدف SVM دقیقاً معادل بیشینه‌سازی پهنای حاشیه است.

۳.۱ قسمت ج: استخراج فرم دوگان و تحلیل بردارهای پشتیبان

۱.۳.۱ چرا به فرم دوگان نیاز داریم؟

فرم دوگان مسئله SVM چندین مزیت مهم دارد:

۱. امکان استفاده از ترفند کرنل (Kernel Trick) برای طبقه‌بندی غیرخطی

۲. پیچیدگی محاسباتی وابسته به تعداد نمونه‌ها (نه ابعاد ویژگی)

۳. درک بهتر نقش بردارهای پشتیبان

۴. سادگی در پیاده‌سازی با الگوریتم‌هایی مانند SMO

۲.۳.۱ مرحله اول: تشکیل تابع لاگرانژی

برای هر قید نامساوی $y_i(w^T x_i + b) \geq 1$ ، یک ضریب لاگرانژ نامنفی $\alpha_i \geq 0$ معرفی می‌کنیم. تابع لاگرانژی به صورت زیر تشکیل می‌شود:

$$\mathcal{L}(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1] \quad (۱۳)$$

توضیح ساختار:

• جمله اول: تابع هدف اصلی

• جمله دوم: جریمه برای نقض قیود (با ضرایب α_i)

با باز کردن تابع لاگرانژی:

$$\mathcal{L} = \frac{1}{2} w^T w - \sum_{i=1}^N \alpha_i y_i w^T x_i - b \sum_{i=1}^N \alpha_i y_i + \sum_{i=1}^N \alpha_i \quad (۱۴)$$



۳.۳.۱ مرحله دوم: شرایط ایستایی (نقطه زینی)

برای یافتن نقطه زینی لاگرانژی، مشتق نسبت به متغیرهای اولیه (w و b) را صفر قرار می‌دهیم.
شرط اول - مشتق نسبت به w :

$$\nabla_w \mathcal{L} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad (15)$$

$$w^* = \sum_{i=1}^N \alpha_i y_i x_i \quad (16)$$

تفسیر: بردار وزن بهینه، ترکیب خطی از نمونه‌های آموزشی است که ضریب هر نمونه برابر $\alpha_i y_i$ است.
شرط دوم - مشتق نسبت به b :

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (17)$$

$$\sum_{i=1}^N \alpha_i y_i = 0 \quad (18)$$

تفسیر: مجموع وزن‌دار ضرایب لاگرانژ (با وزن برچسب کلاس) باید صفر باشد. این تضمین می‌کند که تعادلی بین دو کلاس وجود دارد.

۴.۳.۱ مرحله سوم: جایگزینی و استخراج تابع دوگان

با جایگذاری $w^* = \sum_i \alpha_i y_i x_i$ در تابع لاگرانژی:
جمله اول:

$$\begin{aligned} \frac{1}{2} \|w^*\|^2 &= \frac{1}{2} \left(\sum_i \alpha_i y_i x_i \right)^T \left(\sum_j \alpha_j y_j x_j \right) \\ &= \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j \end{aligned} \quad (19)$$

جمله دوم:

$$\begin{aligned} \sum_i \alpha_i y_i (w^*)^T x_i &= \sum_i \alpha_i y_i \left(\sum_j \alpha_j y_j x_j \right)^T x_i \\ &= \sum_{i,j} \alpha_i \alpha_j y_i y_j x_j^T x_i \end{aligned} \quad (20)$$

جمله سوم: با توجه به $\sum_i \alpha_i y_i = 0$ ، این جمله صفر می‌شود.



جمله چهارم: $\sum_i \alpha_i$ بدون تغییر باقی می‌ماند.
ترکیب جملات:

$$\begin{aligned}\mathcal{L}_D(\alpha) &= \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j + \sum_i \alpha_i \\ &= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j\end{aligned}\quad (21)$$

۵.۳.۱ مرحله چهارم: صورت‌بندی کامل مسئله دوگان

$$\begin{array}{ll}\text{maximize}_{\alpha} & W(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \\ \text{to subject} & \alpha_i \geq 0, \quad \forall i \in \{1, \dots, N\} \\ & \sum_{i=1}^N \alpha_i y_i = 0\end{array}\quad (22)$$

نکات مهم:

- تابع هدف فقط به ضرب داخلی نمونه‌ها $\langle x_i, x_j \rangle$ وابسته است (نه خود نمونه‌ها)
- این خاصیت امکان استفاده از ترفند کرنل را فراهم می‌کند
- ماتریس $Q_{ij} = y_i y_j \langle x_i, x_j \rangle$ نیمه‌معین مثبت است، پس مسئله محدب است

۶.۳.۱ محاسبه بایاس b

پس از یافتن α^* ، بایاس از شرط مکمل بودن محاسبه می‌شود. برای هر بردار پشتیبان (نمونه‌ای با $\alpha_i > 0$):

$$b = y_i - w^T x_i = y_i - \sum_{j=1}^N \alpha_j y_j \langle x_j, x_i \rangle \quad (23)$$

در عمل، برای پایداری عددی، میانگین مقادیر b محاسبه شده از همه بردارهای پشتیبان گرفته می‌شود.

۷.۳.۱ شرایط KKT و بردارهای پشتیبان

شرایط کاروش-کوهن-تاکر (KKT) برای این مسئله شامل موارد زیر است:

شرط مکمل بودن (Complementary Slackness):

$$\alpha_i [y_i (w^T x_i + b) - 1] = 0, \quad \forall i \quad (24)$$

این شرط می‌گوید حداقل یکی از دو عامل زیر باید صفر باشد:



• $\alpha_i = 0$: نمونه تأثیری در تعیین w ندارد

• $y_i(w^T x_i + b) - 1 = 0$: نمونه دقیقاً روی مرز حاشیه قرار دارد

۸.۳.۱ تحلیل کامل سه حالت ممکن

جدول ۱: دسته‌بندی نمونه‌ها بر اساس مقدار α_i

شرط	موقعیت نمونه	نوع نمونه	نقش در مدل
$\alpha_i = 0$	$y_i(w^T x_i + b) > 1$	غیر پشتیبان	بی تأثیر
$\alpha_i > 0$	$y_i(w^T x_i + b) = 1$	بردار پشتیبان	تعیین‌کننده w

نتیجه کلیدی: فقط نمونه‌هایی که روی مرز حاشیه قرار دارند ($\alpha_i > 0$) در تابع تصمیم ظاهر می‌شوند.

۹.۳.۱ تابع تصمیم‌گیری نهایی

$$f(x) = \text{sign} \left(\sum_{i \in SV} \alpha_i y_i \langle x_i, x \rangle + b \right) \quad (25)$$

که $SV = \{i : \alpha_i > 0\}$ مجموعه اندیس‌های بردارهای پشتیبان است.

۱۰.۳.۱ مزایای تنکی جواب

- کارایی حافظه: فقط بردارهای پشتیبان ذخیره می‌شوند (معمولاً بخش کوچکی از داده‌ها)
- سرعت پیش‌بینی: محاسبه $f(x)$ فقط نیاز به جمع روی بردارهای پشتیبان دارد
- تفسیرپذیری: بردارهای پشتیبان، نمونه‌های مرزی و تعیین‌کننده هستند
- مقاومت: تغییر نمونه‌های غیرپشتیبان، مدل را تغییر نمی‌دهد



۲ سوال دوم: حاشیه نرم، متغیرهای کمکی و تابع زیان لولایی

۱.۲ قسمت الف: معرفی متغیرهای کمکی و فرم اولیه

۱.۱.۲ انگیزه: محدودیت‌های حاشیه سخت

در دنیای واقعی، دو مشکل اساسی با مدل حاشیه سخت وجود دارد:

مشکل اول - عدم جداپذیری خطی: بسیاری از مجموعه داده‌ها به صورت خطی جداپذیر نیستند. در این حالت، مسئله بهینه‌سازی حاشیه سخت هیچ جواب شدنی ندارد.

مشکل دوم - حساسیت به نویز: حتی اگر داده‌ها جداپذیر باشند، وجود یک نقطه پرت می‌تواند مرز تصمیم را به شدت منحرف کند و باعث بیش‌برازش شود.

۲.۱.۲ راه‌حل: متغیرهای شل‌شدگی

برای هر نمونه آموزشی i ، یک متغیر کمکی غیر منفی $\xi_i \geq 0$ (خوانده می‌شود «کسای») معرفی می‌کنیم که میزان «تخطی» از قید حاشیه را اندازه می‌گیرد:

$$y_i(w^T x_i + b) \geq 1 - \xi_i \quad (26)$$

۳.۱.۲ تفسیر هندسی متغیرهای شل‌شدگی

جدول ۲: تفسیر مقادیر مختلف ξ_i

مقدار ξ_i	موقعیت نمونه	وضعیت طبقه‌بندی
$\xi_i = 0$	خارج حاشیه، سمت صحیح	صحیح و مطمئن
$0 < \xi_i < 1$	درون حاشیه، سمت صحیح	صحیح ولی نزدیک مرز
$\xi_i = 1$	دقیقاً روی مرز تصمیم	مبهم
$\xi_i > 1$	سمت اشتباه مرز	خطای طبقه‌بندی

نکته مهم: مجموع $\sum_i \xi_i$ کران بالایی برای تعداد خطاهای آموزشی ارائه می‌دهد. اگر $\xi_i > 1$ باشد، نمونه حتماً اشتباه طبقه‌بندی شده است.



۴.۱.۲ فرمول‌بندی مسئله حاشیه نرم با نرم یک

$$\begin{aligned} & \underset{w \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^N}{\text{minimize}} && \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \\ & \text{to subject} && y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \forall i \in \{1, \dots, N\} \\ & && \xi_i \geq 0, \quad \forall i \in \{1, \dots, N\} \end{aligned} \quad (27)$$

۵.۱.۲ تحلیل تابع هدف

تابع هدف دارای دو جزء است:

جزء اول - تنظیم‌گر (پیچیدگی مدل):

$$\frac{1}{2} \|w\|^2$$

این جمله پیچیدگی مدل را کنترل می‌کند. مقدار کوچک‌تر $\|w\|$ به معنای حاشیه بزرگ‌تر و مدل ساده‌تر است.

جزء دوم - جریمه خطا (برازش داده):

$$C \sum_{i=1}^N \xi_i$$

این جمله مجموع تخطی‌ها از حاشیه را جریمه می‌کند.

۶.۱.۲ نقش پارامتر تنظیم C

پارامتر $C > 0$ یک ابرپارامتر است که توازن میان این دو هدف را تعیین می‌کند:

• C بزرگ: اولویت با کاهش خطای آموزشی است (جریمه سنگین برای تخطی)

• C کوچک: اولویت با سادگی مدل است (تحمل بیشتر تخطی)

حالات حدی:

• $C \rightarrow \infty$: مسئله به حاشیه سخت نزدیک می‌شود

• $C \rightarrow 0$: همه داده‌ها نادیده گرفته می‌شوند

۲.۲ قسمت ب: برهان هم‌ارزی با تابع زیان لولایی

۱.۲.۲ هدف اثبات

می‌خواهیم نشان دهیم که مسئله محدودشده حاشیه نرم معادل یک مسئله بهینه‌سازی نامحدود با تابع زیان لولایی (Hinge Loss) است.

این تبدیل درک بهتری از ماهیت SVM به عنوان یک روش یادگیری مبتنی بر زیان ارائه می‌دهد.



۲.۲.۲ گام اول: حذف قیود با جایگزینی

برای مقادیر ثابت w و b ، می‌خواهیم مقدار بهینه ξ_i را بیابیم. از قیود داریم:

$$\xi_i \geq 1 - y_i(w^T x_i + b) \quad (\text{قید حاشیه}) \quad (28)$$

$$\xi_i \geq 0 \quad (\text{نامنفی بودن}) \quad (29)$$

چون در تابع هدف ξ_i با ضریب مثبت C ظاهر می‌شود، برای کمینه‌سازی باید کوچک‌ترین مقدار مجاز را انتخاب کنیم:

$$\xi_i^* = \max(0, 1 - y_i(w^T x_i + b)) \quad (30)$$

۳.۲.۲ گام دوم: تحلیل موردی

حالت اول - نمونه خارج حاشیه و طبقه‌بندی صحیح:

فرض کنید $1 \leq y_i(w^T x_i + b)$. این به معنای آن است که نمونه i با فاصله کافی از مرز تصمیم، در سمت درست قرار دارد.

$$1 - y_i(w^T x_i + b) \leq 0$$

$$\Rightarrow \xi_i^* = \max(0, \text{مقدار غیر مثبت}) = 0$$

نتیجه: این نمونه هیچ جریمه‌ای دریافت نمی‌کند.

حالت دوم - نمونه درون حاشیه یا طبقه‌بندی اشتباه:

فرض کنید $1 > y_i(w^T x_i + b)$. این حالت شامل سه زیرحالت است:

$$1. \quad 0 < y_i(w^T x_i + b) < 1: \text{درون حاشیه ولی سمت درست}$$

$$2. \quad y_i(w^T x_i + b) = 0: \text{روی مرز تصمیم}$$

$$3. \quad y_i(w^T x_i + b) < 0: \text{سمت اشتباه مرز}$$

$$1 - y_i(w^T x_i + b) > 0$$

$$\Rightarrow \xi_i^* = 1 - y_i(w^T x_i + b)$$

نتیجه: جریمه متناسب با میزان تخطی از حاشیه است.

۴.۲.۲ گام سوم: تعریف تابع زیان لولایی

تابع زیان لولایی (Hinge Loss) به صورت زیر تعریف می‌شود:

$$L_{\text{hinge}}(y, f(x)) = \max(0, 1 - y \cdot f(x)) = [1 - y \cdot f(x)]_+ \quad (31)$$

ویژگی‌های تابع زیان لولایی:



- برای نمونه‌های صحیحاً طبقه‌بندی شده با حاشیه کافی: زیان صفر
- برای نمونه‌های نزدیک مرز یا اشتباه: زیان خطی
- محدب و پیوسته (ولی در $0 = 1 - yf(x)$ مشتق‌پذیر نیست)

۵.۲.۲ گام چهارم: فرم معادل نامحدود

با جایگذاری $\xi_i^* = \max(0, 1 - y_i f(x_i))$ در تابع هدف اصلی:

$$J(w, b) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \max(0, 1 - y_i (w^T x_i + b)) \quad (32)$$

یا به صورت فشرده‌تر:

$$J(w, b) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N L_{\text{hinge}}(y_i, f(x_i)) \quad (33)$$

۶.۲.۲ ارتباط با چارچوب تنظیم‌شده

این فرم را می‌توان به صورت یک مسئله تنظیم تیخونوف (Tikhonov Regularization) نوشت:

$$\min_{w, b} \underbrace{\sum_{i=1}^N L_{\text{hinge}}(y_i, f(x_i))}_{\text{زیان تجربی}} + \underbrace{\lambda \|w\|^2}_{\text{جمله تنظیم‌گر}} \quad (34)$$

که در آن $\lambda = \frac{1}{2C}$ است.

۷.۲.۲ مقایسه با سایر توابع زیان

جدول ۳: مقایسه توابع زیان رایج در طبقه‌بندی دودویی

نام	فرمول $L(y, f)$	ویژگی
۱-۰	$\mathbb{I}[yf < 0]$	ناپیوسته، NP-hard
لولایی	$\max(0, 1 - yf)$	محدب، تنک
لجستیک	$\log(1 + e^{-yf})$	محدب، هموار
نمایی	e^{-yf}	محدب، حساس به پرت

چرا زیان لولایی؟

- تقریب محدب خوبی از زیان ۱-۰ است



- منجر به جواب تنگ می‌شود (بردارهای پشتیبان محدود)
- مقاوم‌تر از زیان‌نمایی در برابر داده‌های پرت

۳.۲ قسمت ج: بررسی اثر پارامتر C بر عملکرد مدل

پارامتر C یکی از مهم‌ترین ابرپارامترهای SVM است که مستقیماً بر رفتار مدل و قابلیت تعمیم آن تأثیر می‌گذارد.

۱.۳.۲ دیدگاه نظری: مصالحه بایاس-واریانس

پارامتر C تعادل میان دو هدف متضاد را کنترل می‌کند:

- کمینه‌سازی خطای آموزشی (کاهش بایاس)
- سادگی مدل (کاهش واریانس)

این مصالحه یکی از اصول بنیادین یادگیری ماشین است که در چارچوب‌های مختلف ظاهر می‌شود.

۲.۳.۲ تحلیل دقیق C بزرگ

وقتی $C \rightarrow \infty$:

رفتار بهینه‌سازی:

- جریمه هر واحد تخطی بسیار سنگین می‌شود
 - الگوریتم تلاش می‌کند همه ξ_i را صفر کند
 - در حد، به مسئله حاشیه سخت نزدیک می‌شود
- مشخصات مدل:

- حاشیه باریک

- مرز تصمیم پیچیده و ناهموار

- تعداد کم بردارهای پشتیبان (فقط نقاط مرزی)

- حساسیت بالا به نقاط پرت

از نظر بایاس-واریانس:

- بایاس پایین: مدل به داده‌های آموزشی خوب برازش می‌کند
- واریانس بالا: تغییرات کوچک در داده، مدل را زیاد تغییر می‌دهد
- خطر: بیش‌برازش (Overfitting)



۳.۳.۲ تحلیل دقیق C کوچک

وقتی $0 \rightarrow C$:

رفتار بهینه‌سازی:

- جریمه تخطی ناچیز می‌شود
- الگوریتم روی کمینه‌سازی $\|w\|$ تمرکز می‌کند
- تخطی‌های بزرگ پذیرفته می‌شوند
- مشخصات مدل:
- حاشیه پهن
- مرز تصمیم ساده و هموار
- تعداد زیاد بردارهای پشتیبان
- مقاومت در برابر نویز
- از نظر بایاس-واریانس:
- بایاس بالا: مدل ممکن است الگوهای مهم را نادیده بگیرد
- واریانس پایین: مدل پایدار است
- خطر: کم‌برازش (Underfitting)

۴.۳.۲ تاثیر بر تعداد بردارهای پشتیبان

تعداد بردارهای پشتیبان رابطه معکوس با C دارد. دلیل این موضوع: با C بزرگ:

- فقط نمونه‌های روی مرز حاشیه ($\xi_i = 0$) بردار پشتیبان هستند
- نمونه‌های درون حاشیه یا اشتباه طبقه‌بندی شده تحمل نمی‌شوند
- با C کوچک:
- نمونه‌های بیشتری اجازه تخطی دارند ($\xi_i > 0$)
- همه این نمونه‌ها در دوگان دارای $\alpha_i > 0$ هستند
- پس تعداد بردارهای پشتیبان افزایش می‌یابد



جدول ۴: خلاصه تاثیر پارامتر C بر مشخصات مدل

C	حاشیه	$\ w\ $	خطای آموزش	تعداد SV	خطر
بسیار بزرگ	باریک	بزرگ	کم	کم	بیش‌برازش
متوسط	متعادل	متوسط	متوسط	متوسط	بهینه
بسیار کوچک	پهن	کوچک	زیاد	زیاد	کم‌برازش

۵.۳.۲ جدول خلاصه تاثیرات

۶.۳.۲ روش‌های انتخاب C بهینه

روش اول - اعتبارسنجی متقاطع: K-Fold

۱. مجموعه مقادیر نامزد: $C \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 10^2, 10^3\}$

۲. تقسیم داده به K بخش (معمولا $K = 5$ یا $K = 10$)

۳. برای هر C ، آموزش روی $K - 1$ بخش و ارزیابی روی بخش باقیمانده

۴. انتخاب C با بهترین میانگین عملکرد

روش دوم - جستجوی شبکه‌ای همراه با کرنل:

اگر از کرنل استفاده می‌شود (مثلا RBF با پارامتر γ)، جستجوی شبکه‌ای دوبعدی روی (C, γ) انجام می‌شود.

نکته عملی: معمولا ابتدا جستجوی درشت با گام لگاریتمی بزرگ انجام می‌شود، سپس در اطراف بهترین نقطه، جستجوی ریز صورت

می‌گیرد.



۳ سوال سوم: جریمه مربعی، تفاوت با نرم یک، کرنل و شرایط KKT

۱.۳ قسمت الف: فرم اولیه با جریمه مربعی (نرم دو)

۱.۱.۳ انگیزه استفاده از جریمه مربعی

در فرم‌بندی حاشیه نرم با نرم یک (سوال قبل)، جریمه به صورت خطی با میزان تخطی افزایش می‌یافت. یک جایگزین طبیعی، استفاده از جریمه مربعی است که چندین مزیت دارد:

- تابع هدف کاملاً مشتق‌پذیر و هموار می‌شود
- خطاهای بزرگ‌تر جریمه شدیدتری دریافت می‌کنند
- فرم دوگان ساختار متفاوت و جالبی پیدا می‌کند

۲.۱.۳ فرمول‌بندی مسئله اولیه

$$\begin{aligned} & \underset{w \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^N}{\text{minimize}} && \frac{1}{2} \|w\|^2 + \frac{C}{2} \sum_{i=1}^N \xi_i^2 \\ & \text{to subject} && y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \forall i \in \{1, \dots, N\} \end{aligned} \quad (35)$$

۳.۱.۳ تفاوت‌های کلیدی با فرم نرم یک

جدول ۵: مقایسه فرم‌بندی نرم یک و نرم دو

ویژگی	نرم یک (ℓ_1)	نرم دو (ℓ_2)
جریمه تخطی	$C \sum \xi_i$	$\frac{C}{2} \sum \xi_i^2$
قید نامنفی	$\xi_i \geq 0$ لازم	نیازی نیست
رشد جریمه	خطی	درجه دوم
مشتق‌پذیری	ناپیوسته در صفر	کاملاً هموار

چرا قید $\xi_i \geq 0$ حذف شده؟

در فرم نرم یک، اگر $\xi_i < 0$ مجاز بود، می‌توانستیم با کاهش ξ_i ، تابع هدف را کمتر کنیم. اما در نرم دو، چون ξ_i^2 همواره نامنفی است و تابع سهمی‌وار است، مقدار بهینه ξ_i خودبخود نامنفی خواهد بود (یا دقیقاً صفر یا مثبت).

رشد درجه دوم جریمه:

اگر ξ_i دو برابر شود:

- در نرم یک: جریمه ۲ برابر می‌شود



• در نرم دو: جریمه 4 برابر می‌شود

این یعنی خطاهای بزرگ (نقاط دورتر از مرز) جریمه بسیار سنگین‌تری دریافت می‌کنند.

۲.۳ قسمت ب: استخراج فرم دوگان

۱.۲.۳ تشکیل تابع لاگرانژی

برای هر قید حاشیه، یک ضریب لاگرانژ $\alpha_i \geq 0$ معرفی می‌کنیم. توجه کنید که بر خلاف نرم یک، اینجا ضریب μ_i برای قید $\xi_i \geq 0$ نداریم:

$$\mathcal{L}(w, b, \xi, \alpha) = \frac{1}{2} \|w\|^2 + \frac{C}{2} \sum_{i=1}^N \xi_i^2 - \sum_{i=1}^N \alpha_i [y_i(w^T x_i + b) - 1 + \xi_i] \quad (۳۶)$$

۲.۲.۳ شرایط ایستایی

شرط اول - مشتق نسبت به w :

$$\frac{\partial \mathcal{L}}{\partial w} = w - \sum_{i=1}^N \alpha_i y_i x_i = 0 \quad (۳۷)$$

$$\Rightarrow w^* = \sum_{i=1}^N \alpha_i y_i x_i$$

شرط دوم - مشتق نسبت به b :

$$\frac{\partial \mathcal{L}}{\partial b} = - \sum_{i=1}^N \alpha_i y_i = 0 \quad (۳۸)$$

$$\Rightarrow \sum_{i=1}^N \alpha_i y_i = 0$$

شرط سوم - مشتق نسبت به ξ_i :

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C \xi_i - \alpha_i = 0 \quad (۳۹)$$

$$\Rightarrow \xi_i = \frac{\alpha_i}{C}$$

نکته کلیدی: در نرم یک، رابطه‌ای مستقیم بین ξ_i و α_i وجود نداشت. اما در نرم دو، این رابطه صریح $\xi_i = \frac{\alpha_i}{C}$ بدست می‌آید که پیامدهای مهمی دارد.



۳.۲.۳ جایگزینی و ساده‌سازی

با قرار دادن $\xi_i = \frac{\alpha_i}{C}$ در تابع لاگرانژی:

جمله جریمه مربعی:

$$\frac{C}{2} \sum_i \xi_i^2 = \frac{C}{2} \sum_i \frac{\alpha_i^2}{C^2} = \frac{1}{2C} \sum_i \alpha_i^2$$

جمله $\alpha_i \xi_i$:

$$\sum_i \alpha_i \xi_i = \sum_i \alpha_i \cdot \frac{\alpha_i}{C} = \frac{1}{C} \sum_i \alpha_i^2$$

پس از ترکیب و ساده‌سازی:

$$\begin{aligned} W(\alpha) &= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j x_i^T x_j - \frac{1}{2C} \sum_i \alpha_i^2 \\ &= \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \left(x_i^T x_j + \frac{\delta_{ij}}{C} \right) \end{aligned} \quad (40)$$

۴.۲.۳ فرم دوگان نهایی

$$\begin{aligned} \text{maximize}_{\alpha} \quad & W(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i,j=1}^N \alpha_i \alpha_j y_i y_j \left(x_i^T x_j + \frac{\delta_{ij}}{C} \right) \\ \text{to subject} \quad & \alpha_i \geq 0, \quad \forall i \in \{1, \dots, N\} \\ & \sum_{i=1}^N \alpha_i y_i = 0 \end{aligned} \quad (41)$$

که δ_{ij} نماد کرونکر دلتا است:

$$\delta_{ij} = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

۵.۲.۳ تفسیر: کرنل اصلاح‌شده

فرم دوگان نرم دورا می‌توان به صورت زیر نوشت:

$$W(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \tilde{K}(x_i, x_j)$$

که کرنل اصلاح‌شده $\tilde{K}$ برابر است با:

$$\tilde{K}(x_i, x_j) = K(x_i, x_j) + \frac{\delta_{ij}}{C}$$

تفسیر: افزودن $\frac{1}{C}$ به عناصر قطری ماتریس کرنل، معادل اضافه کردن یک تنظیم‌گر به فضای ویژگی است. این عمل ماتریس کرنل را «تنظیم» می‌کند و از مشکلات عددی جلوگیری می‌کند.



۳.۳ قسمت ج: مقایسه محدودیت‌های ضرایب لاگرانژ

۱.۳.۳ استخراج محدوده α_i در نرم یک

در فرم نرم یک، تابع لاگرانژی شامل ضرایب $\mu_i \geq 0$ برای قیود $\xi_i \geq 0$ است:

$$\mathcal{L} = \frac{1}{2} \|w\|^2 + C \sum_i \xi_i - \sum_i \alpha_i [y_i (w^T x_i + b) - 1 + \xi_i] - \sum_i \mu_i \xi_i$$

شرط ایستایی نسبت به ξ_i :

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \alpha_i - \mu_i = 0$$

$$\Rightarrow \alpha_i = C - \mu_i$$

با توجه به $\mu_i \geq 0$ و $\alpha_i \geq 0$:

$$\boxed{0 \leq \alpha_i \leq C} \quad (42)$$

۲.۳.۳ استخراج محدوده α_i در نرم دو

در فرم نرم دو، قید صریح $\xi_i \geq 0$ وجود ندارد. از شرط ایستایی:

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C \xi_i - \alpha_i = 0$$

$$\Rightarrow \xi_i = \frac{\alpha_i}{C}$$

چون در نقطه بهینه، ξ_i خودبخود نامنفی می‌شود (به دلیل ساختار سهمی وار تابع)، تنها محدودیت $\alpha_i \geq 0$ است:

$$\boxed{0 \leq \alpha_i < \infty} \quad (43)$$

۳.۳.۳ پیامدهای عملی تفاوت محدوده‌ها

تنکی جواب (Sparsity):

در نرم یک، بسیاری از α_i ‌ها دقیقاً صفر یا دقیقاً C می‌شوند. این یعنی جواب تنک است و تعداد بردارهای پشتیبان محدود است. در نرم دو، α_i می‌تواند هر مقدار مثبتی باشد. هر نمونه با کوچکترین تخطی، مقدار مثبت $\alpha_i = C \xi_i$ خواهد داشت، پس جواب غیرتنک می‌شود.

مقاومت به نقاط پرت (Outliers):

در نرم یک، جریمه یک نقطه پرت حداکثر $C \cdot \xi_i$ است که با C محدود می‌شود. در نرم دو، جریمه $\frac{C}{2} \xi_i^2$ است که برای ξ_i بزرگ، بسیار سنگین می‌شود. این باعث می‌شود مدل تلاش کند نقاط پرت را هم برازش کند.



جدول ۶: مقایسه جامع دو روش جریمه‌دهی

ویژگی	نرم یک (ℓ_1)	نرم دو (ℓ_2)
جریمه در اولیه	$C \sum \xi_i$	$\frac{C}{2} \sum \xi_i^2$
محدوده α_i	$[0, C]$	$[0, \infty)$
رابطه α_i و ξ_i	غیر صریح	$\xi_i = \alpha_i / C$
تنکی جواب	بله (کم) SV	خیر (زیاد) SV
مقاومت به پرت‌ها	بالا	پایین
هموار بودن	خیر (در صفر)	بله (همه جا)
کرنل معادل	$K(x_i, x_j)$	$K(x_i, x_j) + \frac{\delta_{ij}}{C}$

۴.۳.۳ جدول مقایسه کامل

۵.۳.۳ کاربردهای هر روش

نرم یک مناسب است برای:

- داده‌هایی با نویز یا نقاط پرت
 - وقتی کارایی حافظه و سرعت پیش‌بینی مهم است
 - تفسیرپذیری مدل (شناسایی نمونه‌های مرزی)
- نرم دو مناسب است برای:

- داده‌های تمیز با کمترین نویز
- وقتی مشتق‌پذیری و همواری مهم است
- الگوریتم‌های گرادیان-محور

۴.۳ قسمت د: مفهوم کرنل معتبر و ترفند کرنل

۱.۴.۳ انگیزه: طبقه‌بندی غیر خطی

بسیاری از مسائل واقعی به صورت خطی جداپذیر نیستند. یک راه‌حل، نگاشت داده‌ها به فضای بالاتر است که در آن خطی جداپذیر شوند:

$$\phi: \mathbb{R}^d \rightarrow \mathbb{R}^D, \quad D \gg d$$

مشکل: محاسبه صریح $\phi(x)$ برای فضای بالابعدی گران است.
راه‌حل: ترفند کرنل!



۲.۴.۳ ترفند کرنل

در فرم دوگان SVM، داده‌ها فقط در ضرب داخلی ظاهر می‌شوند:

$$W(\alpha) = \sum_i \alpha_i - \frac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle$$

اگر بتوانیم ضرب داخلی در فضای ویژگی را مستقیماً محاسبه کنیم بدون اینکه ϕ را صریحاً بدانیم:

$$K(x, z) = \langle \phi(x), \phi(z) \rangle$$

آنگاه می‌توانیم از SVM غیرخطی استفاده کنیم بدون هزینه محاسباتی نگاشت صریح.

۳.۴.۳ تعریف رسمی کرنل معتبر

تعریف: تابع $K : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ یک کرنل معتبر (یا کرنل مرسر) نامیده می‌شود اگر و تنها اگر برای هر مجموعه متناهی $\{x_1, \dots, x_n\} \subset \mathcal{X}$ ، ماتریس گرام $\mathbf{K} \in \mathbb{R}^{n \times n}$ با درایه‌های $K_{ij} = K(x_i, x_j)$ نیمه‌معین مثبت باشد.

شرط نیمه‌معین مثبت:

$$\sum_{i=1}^n \sum_{j=1}^n c_i c_j K(x_i, x_j) \geq 0, \quad \forall c \in \mathbb{R}^n, \forall n \in \mathbb{N}$$

معادلاً، همه مقادیر ویژه ماتریس $\mathbf{K}$ نامنفی هستند.

۴.۴.۳ قضیه مرسر

قضیه مرسر: تابع K یک کرنل معتبر است اگر و تنها اگر نگاشت ویژگی $\phi : \mathcal{X} \rightarrow \mathcal{H}$ به یک فضای هیلبرت $\mathcal{H}$ وجود داشته باشد به طوری که:

$$K(x, z) = \langle \phi(x), \phi(z) \rangle_{\mathcal{H}}$$

نکته مهم: فضای هیلبرت $\mathcal{H}$ می‌تواند ابعاد بسیار بالا یا حتی نامتناهی داشته باشد، اما محاسبه $K(x, z)$ همچنان با هزینه محدود انجام می‌شود.

۵.۴.۳ مثال: کرنل چندجمله‌ای درجه ۲

برای $x, z \in \mathbb{R}^2$:

$$\begin{aligned} K(x, z) &= (x^T z)^2 = (x_1 z_1 + x_2 z_2)^2 \\ &= x_1^2 z_1^2 + 2x_1 x_2 z_1 z_2 + x_2^2 z_2^2 \end{aligned}$$

نگاشت ویژگی متناظر:

$$\phi(x) = (x_1^2, \sqrt{2}x_1 x_2, x_2^2)^T$$

بررسی: $\langle \phi(x), \phi(z) \rangle = K(x, z)$



۵.۳ قسمت ۵: اثبات اعتبار کرنل‌های متداول

۱.۵.۳ خواص بستاری کرنل‌ها

اگر K_1 و K_2 کرنل‌های معتبر باشند، عملیات زیر نیز کرنل معتبر تولید می‌کنند:

جدول ۷: خواص بستاری کرنل‌های معتبر

عملیات	نتیجه	شرط
جمع	$K_1 + K_2$	همیشه معتبر
ضرب	$K_1 \cdot K_2$	همیشه معتبر
ضرب در ثابت	$c \cdot K_1$	$c > 0$
نمایی	$\exp(K_1)$	همیشه معتبر
تابع چند جمله‌ای	$p(K_1)$	ضرایب نامنفی

۲.۵.۳ کرنل خطی

ساده‌ترین کرنل:

$$K_{\text{lin}}(x, z) = x^T z = \langle x, z \rangle$$

اثبات اعتبار:

$$\sum_{i,j} c_i c_j K(x_i, x_j) = \sum_{i,j} c_i c_j x_i^T x_j = \left\| \sum_i c_i x_i \right\|^2 \geq 0$$

۳.۵.۳ کرنل چند جمله‌ای

$$K_{\text{poly}}(x, z) = (x^T z + c)^d, \quad c \geq 0, d \in \mathbb{N}$$

اثبات اعتبار:

گام ۱: $K_0(x, z) = x^T z$ کرنل خطی و معتبر است.

گام ۲: $K_1(x, z) = x^T z + c$ معتبر است زیرا افزودن ثابت مثبت به ضرب داخلی معادل افزودن بعد ثابت به بردارها است:

$$\tilde{x} = [x; \sqrt{c}] \Rightarrow \tilde{x}^T \tilde{z} = x^T z + c$$

گام ۳: $K(x, z) = K_1^d$ معتبر است زیرا از خاصیت بستاری نسبت به ضرب، حاصل ضرب d کرنل معتبر، کرنل معتبر است.

۴.۵.۳ کرنل گاوسی (RBF)

$$K_{\text{RBF}}(x, z) = \exp(-\gamma \|x - z\|^2), \quad \gamma > 0$$



اثبات اعتبار (روش بسط سری):

گام ۱: بسط نرم مربع:

$$\|x - z\|^2 = \|x\|^2 + \|z\|^2 - 2x^T z$$

گام ۲: جداسازی:

$$\begin{aligned} K(x, z) &= \exp(-\gamma\|x\|^2) \cdot \exp(-\gamma\|z\|^2) \cdot \exp(2\gamma x^T z) \\ &= g(x) \cdot g(z) \cdot \exp(2\gamma x^T z) \end{aligned} \quad (44)$$

گام ۳: بسط سری تیلور نمایی:

$$\exp(2\gamma x^T z) = \sum_{n=0}^{\infty} \frac{(2\gamma)^n}{n!} (x^T z)^n$$

هر جمله $(x^T z)^n$ یک کرنل چندجمله‌ای معتبر است. جمع بی‌نهایت کرنل‌های معتبر با ضرایب مثبت، همچنان معتبر است.

گام ۴: ضرب در $g(x) \cdot g(z)$ معادل ضرب ویژگی‌ها در یک تابع است که اعتبار را حفظ می‌کند.

۵.۵.۳ ابعاد فضای ویژگی کرنل‌ها

جدول ۸: ابعاد فضای ویژگی ضمنی

توضیح	ابعاد ویژگی	کرنل
همان ابعاد ورودی	d	خطی
ترکیبی از تک‌جمله‌ای‌ها	$\binom{d+n}{n}$	چندجمله‌ای درجه d
فضای هیلبرت نامتناهی بعد	∞	گاوسی (RBF)

۶.۳ قسمت و: شرایط KKT برای مدل نرم دو

شرایط کاروش-کوهن-تاکر (KKT) شرایط لازم و کافی برای بهینگی در مسائل بهینه‌سازی محدب هستند.

۱.۶.۳ شرایط KKT برای مسئله نرم دو

۱. شرط ایستایی (Stationarity):

مشتق لاگرانژی نسبت به متغیرهای اولیه صفر است:

$$\nabla_w \mathcal{L} = 0 \quad \Rightarrow \quad w = \sum_{i=1}^N \alpha_i y_i x_i \quad (45)$$

$$\frac{\partial \mathcal{L}}{\partial b} = 0 \quad \Rightarrow \quad \sum_{i=1}^N \alpha_i y_i = 0 \quad (46)$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = 0 \quad \Rightarrow \quad C \xi_i = \alpha_i \quad \Rightarrow \quad \xi_i = \frac{\alpha_i}{C} \quad (47)$$



۲. شرط امکان‌پذیری اولیه (Primal Feasibility):

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \forall i \in \{1, \dots, N\}$$

۳. شرط امکان‌پذیری دوگان (Dual Feasibility):

$$\alpha_i \geq 0, \quad \forall i \in \{1, \dots, N\}$$

۴. شرط مکمل‌بودن (Complementary Slackness):

$$\alpha_i [y_i(w^T x_i + b) - 1 + \xi_i] = 0, \quad \forall i$$

۲.۶.۳ تحلیل کامل حالات بر اساس شرایط KKT

با ترکیب شرط مکمل‌بودن و رابطه $\xi_i = \frac{\alpha_i}{C}$:

حالت ۱: $\alpha_i = 0$

• از $\xi_i = \alpha_i / C$ نتیجه می‌شود $\xi_i = 0$

• شرط مکمل‌بودن به طور خودکار برقرار است

• شرط امکان‌پذیری اولیه می‌شود: $y_i(w^T x_i + b) \geq 1$

• تفسیر: نمونه خارج حاشیه است و بردار پشتیبان نیست

حالت ۲: $\alpha_i > 0$

• از $\xi_i = \alpha_i / C > 0$ نتیجه می‌شود $\xi_i > 0$

• شرط مکمل‌بودن ایجاب می‌کند: $y_i(w^T x_i + b) - 1 + \xi_i = 0$

• پس: $y_i(w^T x_i + b) = 1 - \xi_i < 1$

• تفسیر: نمونه درون حاشیه یا سمت اشتباه است و بردار پشتیبان است

۳.۶.۳ خلاصه حالات در جدول

جدول ۹: دسته‌بندی نمونه‌ها بر اساس شرایط KKT در نرم دو

نوع	موقعیت	$y_i(w^T x_i + b)$	ξ_i	α_i
SV غیر	خارج حاشیه	≥ 1	$= 0$	$= 0$
SV	درون حاشیه	$= 1 - \xi_i$	> 0	> 0



جدول ۱۰: مقایسه حالات KKT در دو مدل

ویژگی	نرم یک	نرم دو
تعداد حالات متمایز	۳	۲
امکان $0 < \alpha_i < C$	بله	خیر
بردار پشتیبان آزاد	بله (روی مرز حاشیه)	خیر
تنکی	بله	خیر

۴.۶.۳ مقایسه با شرایط KKT در نرم یک

۵.۶.۳ نتیجه‌گیری مهم

در مدل با نرم دو:

- هر نمونه‌ای که $\xi_i > 0$ داشته باشد (کوچکترین تخطی از حاشیه)، بردار پشتیبان می‌شود
- رابطه خطی $\alpha_i = C\xi_i$ وجود دارد
- جواب‌ها معمولاً غیرتنک هستند (تعداد زیادی SV)
- این ویژگی در مقایسه با نرم یک، حافظه و زمان پیش‌بینی بیشتری می‌طلبد



۴ سوال پنجم: حل دستی SVM برای داده‌های دوبعدی

۱.۴ معرفی مسئله و داده‌ها

مجموعه داده:

هشت نمونه در فضای دوبعدی $\mathbb{R}^2$ داده شده‌اند:

جدول ۱۱: داده‌های آموزشی

انديس	$x = (x_1, x_2)$	برچسب y	کلاس
۱	(2, 0)	+1	مثبت
۲	(3, 0)	+1	مثبت
۳	(2, 1)	+1	مثبت
۴	(2, -1)	+1	مثبت
۵	(-2, 0)	-1	منفی
۶	(-3, 0)	-1	منفی
۷	(-2, -1)	-1	منفی
۸	(-2, 1)	-1	منفی

۲.۴ قسمت الف: تحلیل هندسی و حدس مرز تصمیم

۱.۲.۴ بررسی توزیع داده‌ها

با مشاهده دقیق داده‌ها:

کلاس مثبت ($y = +1$):

• همه نمونه‌ها دارای $x_1 \geq 2$ هستند

• نزدیک‌ترین نقاط به مبدا: (2, 0)، (2, 1)، (2, -1) با $x_1 = 2$

• دورترین نقطه: (3, 0) با $x_1 = 3$

کلاس منفی ($y = -1$):

• همه نمونه‌ها دارای $x_1 \leq -2$ هستند

• نزدیک‌ترین نقاط به مبدا: (-2, 0)، (-2, 1)، (-2, -1) با $x_1 = -2$

• دورترین نقطه: (-3, 0) با $x_1 = -3$



۲.۲.۴ خواص تقارنی

- داده‌ها نسبت به محور x_1 (یعنی $x_2 = 0$) تقارن آینه‌ای دارند
- داده‌ها نسبت به محور x_2 (یعنی $x_1 = 0$) تقارن نقطه‌ای دارند (با تعویض برچسب)
- نزدیک‌ترین نقاط دو کلاس، فاصله ۴ واحد از هم دارند (مثلاً $(2, 0)$ و $(-2, 0)$)

۳.۲.۴ استنتاج مرز بهینه

با توجه به تقارن داده‌ها و فاصله مساوی دو کلاس از مبدا، بهترین ابرصفحه جداکننده:

$$(48) \quad w_2 = 0, b = 0 \text{ یا } w_1 x_1 + w_2 x_2 + b = 0 \quad \text{یا} \quad x_1 = 0 \quad \text{مرز تصمیم:}$$

این خط عمودی از مبدا می‌گذرد و موازی محور x_2 است.

۳.۴ قسمت ب: محاسبه پارامترهای مدل

۱.۳.۴ شناسایی بردارهای پشتیبان احتمالی

بردارهای پشتیبان نقاطی هستند که روی مرز حاشیه قرار دارند (یعنی $y_i(w^T x_i + b) = 1$). از تحلیل هندسی، نقاط با $x_1 = \pm 2$ نزدیک‌ترین به مرز هستند.

نامزدهای بردار پشتیبان مثبت: $(2, 0)$ ، $(2, 1)$ ، $(2, -1)$

نامزدهای بردار پشتیبان منفی: $(-2, 0)$ ، $(-2, 1)$ ، $(-2, -1)$

۲.۳.۴ تشکیل دستگاه معادلات

فرض کنید $w = [w_1, w_2]^T \in \mathbb{R}^2$ و $b \in \mathbb{R}$. برای بردارهای پشتیبان، شرط مرزی برقرار است:

معادله ۱ - از $(2, 0)$ با $y = +1$:

$$w^T x + b = +1 \Rightarrow 2w_1 + 0 \cdot w_2 + b = 1$$

$$(49) \quad 2w_1 + b = 1$$

معادله ۲ - از $(-2, 0)$ با $y = -1$:

$$w^T x + b = -1 \Rightarrow -2w_1 + 0 \cdot w_2 + b = -1$$

$$(50) \quad -2w_1 + b = -1$$



۳.۳.۴ حل دستگاه معادلات

یافتن b :

جمع معادلات (۴۹) و (۵۰):

$$(2w_1 + b) + (-2w_1 + b) = 1 + (-1)$$

$$2b = 0$$

$$b = 0$$

یافتن w_1 :

جایگذاری $b = 0$ در معادله (۴۹):

$$2w_1 + 0 = 1$$

$$w_1 = \frac{1}{2} = 0.5$$

یافتن w_2 :

از تقارن مسئله و اینکه مرز تصمیم نباید به x_2 وابسته باشد:

$$w_2 = 0$$

تایید: نقاط $(2, 1)$ و $(2, -1)$ نیز باید روی مرز حاشیه باشند:

$$w^T(2, 1) + b = 0.5 \times 2 + 0 \times 1 + 0 = 1 \quad \checkmark$$

$$w^T(2, -1) + b = 0.5 \times 2 + 0 \times (-1) + 0 = 1 \quad \checkmark$$

۴.۳.۴ نتایج

$$w = \begin{bmatrix} 0.5 \\ 0 \end{bmatrix}, \quad b = 0 \quad (51)$$

معادله مرز تصمیم:

$$w^T x + b = 0 \Rightarrow 0.5x_1 + 0 \cdot x_2 + 0 = 0 \Rightarrow x_1 = 0$$

معادله مرزهای حاشیه:

$$H_+ : \quad 0.5x_1 = +1 \Rightarrow x_1 = +2$$

$$H_- : \quad 0.5x_1 = -1 \Rightarrow x_1 = -2$$



۴.۴ قسمت ج: محاسبه حاشیه و تعیین بردارهای پشتیبان

۱.۴.۴ شناسایی دقیق بردارهای پشتیبان

بردارهای پشتیبان نقاطی هستند که دقیقاً روی مرز حاشیه قرار دارند، یعنی $y_i(w^T x_i + b) = 1$. بررسی نقاط کلاس مثبت:

نقطه	$w^T x + b$	$y(w^T x + b)$	SV?
(2, 0)	$0.5 \times 2 = 1$	$+1 \times 1 = 1$	بله
(3, 0)	$0.5 \times 3 = 1.5$	$+1 \times 1.5 = 1.5$	خیر
(2, 1)	$0.5 \times 2 = 1$	$+1 \times 1 = 1$	بله
(2, -1)	$0.5 \times 2 = 1$	$+1 \times 1 = 1$	بله

بررسی نقاط کلاس منفی:

نقطه	$w^T x + b$	$y(w^T x + b)$	SV?
(-2, 0)	$0.5 \times (-2) = -1$	$-1 \times (-1) = 1$	بله
(-3, 0)	$0.5 \times (-3) = -1.5$	$-1 \times (-1.5) = 1.5$	خیر
(-2, -1)	$0.5 \times (-2) = -1$	$-1 \times (-1) = 1$	بله
(-2, 1)	$0.5 \times (-2) = -1$	$-1 \times (-1) = 1$	بله

مجموعه بردارهای پشتیبان:

$$SV = \{(2, 0), (2, 1), (2, -1), (-2, 0), (-2, -1), (-2, 1)\}$$

تعداد کل: ۶ بردار پشتیبان

نقاط (3, 0) و (-3, 0) بردار پشتیبان نیستند زیرا خارج از حاشیه قرار دارند ($y(w^T x + b) > 1$).

۲.۴.۴ محاسبه نرم بردار وزن

$$\|w\| = \sqrt{w_1^2 + w_2^2} = \sqrt{0.5^2 + 0^2} = \sqrt{0.25} = 0.5$$

۳.۴.۴ محاسبه حاشیه هندسی

حاشیه هندسی (فاصله از مرز تصمیم تا مرز حاشیه):

$$\gamma = \frac{1}{\|w\|} = \frac{1}{0.5} = 2$$

این به معنای آن است که هر بردار پشتیبان فاصله ۲ واحد از مرز تصمیم ($x_1 = 0$) دارد.



۴.۴.۴ محاسبه پهنای کل حاشیه

پهنای حاشیه (فاصله بین دو مرز حاشیه):

$$\text{پهنای کل} = \frac{2}{\|w\|} = \frac{2}{0.5} = 4$$

تایید هندسی: فاصله $H_+ : x_1 = 2$ تا $H_- : x_1 = -2$ برابر $4 - (-2) = 2$ است.

۵.۴.۴ محاسبه فاصله نقاط مختلف

جدول ۱۲: فاصله هر نقطه از مرز تصمیم

نقطه	فاصله از مرز $\frac{ w^T x + b }{\ w\ }$	توضیح
$(2, 0)$	$\frac{ 1 }{0.5} = 2$	روی مرز حاشیه
$(3, 0)$	$\frac{ 1.5 }{0.5} = 3$	خارج حاشیه
$(-2, 0)$	$\frac{ -1 }{0.5} = 2$	روی مرز حاشیه
$(-3, 0)$	$\frac{ -1.5 }{0.5} = 3$	خارج حاشیه

۶.۴.۴ جدول خلاصه نتایج

جدول ۱۳: خلاصه نتایج محاسبات دستی SVM

کمیت	نماد	مقدار
بردار وزن	w	$[0.5, 0]^T$
بایاس	b	0
نرم وزن	$\ w\ $	0.5
معادله مرز تصمیم	$w^T x + b = 0$	$x_1 = 0$
معادله H_+	$w^T x + b = 1$	$x_1 = 2$
معادله H_-	$w^T x + b = -1$	$x_1 = -2$
حاشیه یک طرفه	$\gamma = 1/\ w\ $	2
پهنای کل حاشیه	$2/\ w\ $	4
تعداد بردارهای پشتیبان	$ SV $	6



۵ سوال ششم: مقایسه شبکه‌های عصبی برای داده‌های خوشه‌ای

۱.۵ توصیف مسئله

مجموعه داده‌ای با ساختار دولا به‌ای (حلقوی یا خوشه‌ای) در نظر گرفته شده که در آن:

- داده‌های آموزشی در نواحی مشخص (مثلاً گوشه‌های فضا) متمرکز شده‌اند
 - نقاط جدید (ستاره‌های سیاه) در ناحیه مرکزی فضا قرار دارند
 - هدف طبقه‌بندی صحیح تمام نقاط است
- این نوع داده‌ها چالش خاصی برای مدل‌های یادگیری ماشین ایجاد می‌کنند زیرا ناحیه مرکزی از داده‌های آموزشی خالی است.

۲.۵ قسمت الف: پیشنهاد معماری مناسب

۱.۲.۵ انتخاب پیشنهادی

پیشنهاد: شبکه عصبی با توابع پایه شعاعی (Radial Basis Function Network - RBF Network)

۲.۲.۵ دلایل انتخاب شبکه RBF

۱. تقریب محلی (Local Approximation):

شبکه RBF از توابع پایه محلی استفاده می‌کند. هر نرون پنهان فقط در همسایگی مرکز خود فعال است:

$$\phi_j(x) = \exp\left(-\frac{\|x - c_j\|^2}{2\sigma_j^2}\right)$$

برای x دور از c_j ، مقدار $\phi_j(x) \approx 0$ است.

۲. رفتار مناسب در نواحی ناشناخته:

وقتی نقطه تست x از همه مراکز c_j دور باشد:

$$\phi_j(x) \approx 0 \quad \forall j \Rightarrow y(x) \approx w_0 \text{ (بایاس)}$$

این یعنی شبکه برای نواحی ناشناخته خروجی نامطمئن (نزدیک صفر یا بایاس) می‌دهد.

۳. تفکیک خوشه‌های محلی:

با قرار دادن مراکز RBF روی خوشه‌های داده، شبکه می‌تواند:

- هر خوشه را جداگانه مدل کند
- نواحی بین خوشه‌ها را «خالی» در نظر بگیرد
- برای نقاط مرکزی که بین خوشه‌ها هستند، خروجی نامشخص دهد



۳.۲.۵ معماری پیشنهادی شبکه RBF

- لایه ورودی: ابعاد ویژگی‌های داده
- لایه پنهان: نرون‌های RBF با مراکز c_j و شعاع‌های σ_j
- لایه خروجی: ترکیب خطی خروجی‌های لایه پنهان

$$y(x) = \sum_{j=1}^M w_j \phi_j(x) + w_0 = \sum_{j=1}^M w_j \exp\left(-\frac{\|x - c_j\|^2}{2\sigma_j^2}\right) + w_0$$

۴.۲.۵ گزینه‌های جایگزین

SVM با کرنل RBF

از نظر ریاضی مشابه شبکه RBF است و همان مزایای تقریب محلی را دارد.
k-NN با آستانه فاصله:
می‌تواند برای نقاط دور از همه داده‌های آموزشی، برچسب «نامشخص» برگرداند.

۳.۵ قسمت ب: تحلیل ضعف شبکه‌های پرسپترون چندلایه

۱.۳.۵ ساختار ریاضی شبکه MLP

شبکه پرسپترون چندلایه (Multi-Layer Perceptron) از نرون‌هایی با ساختار زیر تشکیل شده:

$$z = \sigma(w^T x + b) = \sigma\left(\sum_{i=1}^d w_i x_i + b\right)$$

که σ تابع فعال‌سازی (مانند سیگموئید، tanh، یا ReLU) است.

۲.۳.۵ مشکل اول: تقسیم سراسری فضا

ابرصفحات نامحدود:

هر نرون در MLP یک ابرصفحه $w^T x + b = 0$ تعریف می‌کند که فضا را به دو نیم‌فضا تقسیم می‌کند. این ابرصفحات:

- تا بی‌نهایت امتداد دارند
 - نمی‌توانند نواحی بسته و محدود ایجاد کنند
 - برای ایجاد ناحیه محدود، ترکیب پیچیده‌ای از نرون‌ها لازم است
- مثال: برای محصور کردن یک دایره، MLP نیاز به تعداد زیادی نرون دارد که مماس‌هایی روی دایره بسازند. این در حالی است که یک نرون RBF به راحتی این کار را انجام می‌دهد.



۳.۳.۵ مشکل دوم: برون‌یابی نامناسب (اطمینان کاذب)

رفتار توابع فعال‌سازی در بی‌نهایت:

جدول ۱۴: رفتار توابع فعال‌سازی MLP در $|x| \rightarrow \infty$

تابع	فرمول	حد در $\pm\infty$
سیگموئید	$\frac{1}{1+e^{-z}}$	$\{0, 1\}$
$\tanh$	$\frac{e^z - e^{-z}}{e^z + e^{-z}}$	$\{-1, +1\}$
ReLU	$\max(0, z)$	$\{0, +\infty\}$

پیامد: برای نقطه x که بسیار دور از داده‌های آموزشی است:

مقدار قطعی (۰ یا ۱) $\rightarrow \text{MLP}(x)$

این یعنی شبکه با اطمینان کامل پیش‌بینی می‌کند، در حالی که هیچ داده آموزشی در آن ناحیه ندیده است!

۴.۳.۵ مشکل سوم: عدم توانایی در تشخیص «نمی‌دانم»

MLP استاندارد قادر نیست برای نقاط ناشناخته خروجی «نامشخص» بدهد. این در کاربردهایی که امنیت مهم است (مثلاً تشخیص چهره در سیستم امنیتی) مشکل‌ساز است.

۵.۳.۵ تحلیل ریاضی برتری شبکه RBF

ساختار نرون RBF:

$$\phi(x) = \exp\left(-\frac{\|x - c\|^2}{2\sigma^2}\right)$$

رفتار در فاصله دور:

$$\|x - c\| \rightarrow \infty \Rightarrow \phi(x) \rightarrow 0$$

خروجی شبکه برای نقطه دور از همه مراکز:

$$y(x) = \sum_{j=1}^M w_j \underbrace{\phi_j(x)}_{\approx 0} + w_0 \approx w_0$$

اگر $w_0 = 0.5$ (وسط دو کلاس) باشد، شبکه برای نقاط ناشناخته خروجی نامطمئن می‌دهد.

۶.۳.۵ مقایسه رفتار در ناحیه مرکزی

فرض کنید داده‌های آموزشی در چهار گوشه فضا و نقطه تست در مرکز باشد:

MLP:

- ابرصفحات از میان مرکز عبور می‌کنند



• مرکز در یکی از نیم‌فضاها قرار می‌گیرد

• پیش‌بینی قطعی و احتمالاً اشتباه

RBF:

• مراکز در گوشه‌ها هستند

• همه توابع پایه در مرکز نزدیک صفر هستند

• خروجی نامشخص (اعتراف به عدم اطلاع)

۷.۳.۵ جدول مقایسه جامع

جدول ۱۵: مقایسه جامع معماری‌های MLP و RBF

ویژگی	MLP (سیگموئید/ReLU)	RBF (گوسی)
نوع تقریب	سراسری (Global)	محلی (Local)
پایه ریاضی نرون	ضرب داخلی $w^T x$	فاصله $\ x - c\ $
شکل مرز تصمیم	ابرصفحات نامحدود	نواحی محدود
رفتار در $\ x\ \rightarrow \infty$	$\sigma \rightarrow \{0, 1\}$	$\phi \rightarrow 0$
برون‌یابی	اطمینان کاذب	عدم اطمینان
تشخیص «نمی‌دانم»	خیر	بله
مناسب داده خوشه‌ای	ضعیف	عالی

۸.۳.۵ نتیجه‌گیری

چرا MLP برای این مسئله مناسب نیست:

۱. مرزهای تصمیم سراسری نمی‌توانند خوشه‌های محلی را به خوبی جدا کنند

۲. در نواحی خالی (مرکز)، MLP پیش‌بینی قطعی و اغلب اشتباه می‌دهد

۳. توانایی تشخیص نقاط خارج از توزیع (Out-of-Distribution) را ندارد

چرا RBF مناسب است:

۱. هر نرون یک ناحیه محلی را پوشش می‌دهد

۲. برای نقاط دور از همه مراکز، خروجی به صفر میل می‌کند

۳. رفتار محافظه‌کارانه در نواحی ناشناخته دارد



توصیه نهایی:

برای داده‌هایی با ساختار خوشه‌ای و فضاهاى خالی بین کلاس‌ها، استفاده از:

- شبکه عصبی RBF
- SVM با کرنل RBF (گاوسی)
- مدل‌های مبتنی بر فاصله مانند k -NN با رد نقاط دور



۶ پیاده‌سازی شبکه عصبی RBF

هدف این سوال، مدل‌سازی یک سیستم دینامیکی غیرخطی با استفاده از شبکه عصبی با تابع شعاعی پایه (RBF Neural Network) است. سیستم Ball and Beam یک مسئله کلاسیک در کنترل است که رفتار غیرخطی پیچیده‌ای دارد. شبکه RBF به دلیل قابلیت تقریب توابع غیرخطی با دقت بالا، انتخاب مناسبی برای این مسئله است.

۱.۶ قسمت اول: شبکه RBFNN ایستا

۱.۱.۶ بخش اول: ایجاد دیتاست Ball and Beam

بند ۱.۱.۱ - تولید داده:

سیستم Ball and Beam با معادله تفاضلی زیر تعریف می‌شود:

$$y(t) = \frac{y(t-1)}{1+y(t-2)} + u(t-1)^3 \quad (52)$$

برای تحریک سیستم از سیگنال سینوسی زیر استفاده شده است:

$$u(t) = \sin\left(\frac{2\pi t}{250}\right) \quad (53)$$

مشخصات دیتاست تولید شده:

- تعداد کل نمونه‌ها: ۱۰۰۰
- شرایط اولیه: $y(0) = y(1) = 0$
- بردار ورودی: $x(t) = [y(t-1), y(t-2), u(t-1)]^T$
- خروجی هدف: $y(t)$

بند ۱.۱.۲ - تقسیم داده به آموزش و تست:

داده‌ها به دو بخش تقسیم شده‌اند:


- داده آموزش: ۷۰۰ نمونه اول
- داده تست: ۲۹۸ نمونه باقی‌مانده

بند ۱.۱.۳ - مسئله تقریب تابع:

این مسئله یک مسئله تقریب تابع (Function Approximation) است زیرا هدف یادگیری یک نگاشت غیرخطی از ورودی به خروجی است:

$$f: \mathbb{R}^3 \rightarrow \mathbb{R}, \quad f(x(t)) \approx y(t) \quad (54)$$

شبکه RBFNN سعی دارد تابع غیرخطی [رابطه ۵۲](#) را با استفاده از ترکیب توابع گوسی تقریب بزند.



شکل ۱: سیگنال ورودی و خروجی سیستم Ball and Beam

۲.۱.۶ بخش دوم: پیاده‌سازی RBFNN ایستا

یک شبکه RBFNN شامل سه لایه است:

۱. لایه ورودی: دریافت بردار ورودی x
 ۲. لایه مخفی: K نورون RBF با تابع فعال‌سازی گوسی
 ۳. لایه خروجی: ترکیب خطی خروجی نورون‌های مخفی
- خروجی شبکه به صورت زیر محاسبه می‌شود:

$$f(x) = \sum_{k=1}^K \alpha_k \phi_k(x) \quad (55)$$

که در آن α_k وزن‌های خروجی و $\phi_k(x)$ تابع فعال‌سازی گوسی است:

$$\phi_k(x) = \exp\left(-\frac{\|x - \mu_k\|^2}{\sigma_k^2}\right) \quad (56)$$

بند ۱.۲.۱ - نقش مرکز و عرض نورون:

مرکز نورون (μ_k) :

- تعیین‌کننده موقعیت نورون در فضای ورودی
- نورون بیشترین پاسخ (خروجی ۱) را به ورودی‌های روی مرکز خود می‌دهد




• هرچه ورودی از مرکز دورتر شود، خروجی کاهش می‌یابد

عرض نرون (σ_k):

• تعیین‌کننده ناحیه تأثیر نرون

• σ کوچک: تابع باریک و تیز (پاسخ به ورودی‌های نزدیک)

• σ بزرگ: تابع پهن و صاف (پاسخ به محدوده وسیع‌تر)



شکل ۲: تأثیر مرکز (μ) و عرض (σ) بر تابع فعال‌سازی RBF

بند ۱.۲.۲ - تعریف و تست تابع RBF:


تابع RBF گوسی با مرکز $\mu = [1, 1]$ و عرض $\sigma = 1$ تست شد:

جدول ۱۶: نتایج تست تابع RBF با $\mu = [1, 1]$ و $\sigma = 1$

ورودی x	فاصله از مرکز	خروجی $\phi(x)$
$[1, 1]$	0.0000	1.000000
$[0.5, 0.5]$	0.7071	0.606531
$[1, 0]$	1.0000	0.367879
$[0, 0]$	1.4142	0.135335
$[2, 2]$	1.4142	0.135335

همان‌طور که مشاهده می‌شود، وقتی ورودی دقیقاً روی مرکز قرار دارد، خروجی برابر ۱ (حداکثر) است و با دور شدن از مرکز، خروجی کاهش می‌یابد.

تحلیل منطقی نتایج: این رفتار دقیقاً مطابق فرمول گوسی $\phi(x) = e^{-\|x-\mu\|^2/\sigma^2}$ است. وقتی فاصله صفر است، توان صفر می‌شود و $e^0 = 1$. با افزایش فاصله، توان منفی‌تر شده و خروجی به سمت صفر میل می‌کند. این ویژگی باعث می‌شود هر نرون RBF فقط به ورودی‌های نزدیک به مرکز خود پاسخ دهد و یک «ناحیه پذیرش» محلی داشته باشد.



شکل ۳: نمایش سه‌بعدی و کانتور تابع فعال‌سازی RBF گوسی

شبکه RBFNN با روش زیر آموزش داده شد:

۱. تعیین مراکز (μ_k) با الگوریتم K-Means

۲. محاسبه عرض‌ها (σ_k) بر اساس فاصله بین مراکز

۳. آموزش وزن‌های خروجی (α_k) با روش حداقل مربعات خطی (Least Squares)


نتایج با ۲۵ نورون مخفی:

جدول ۱۷: معیارهای عملکرد شبکه RBFNN با $K = 25$ نورون

معیار	آموزش	تست
MSE	14.0857	24.4428
RMSE	3.7531	4.9440
MAE	1.4235	1.8312
R ² Score	0.9249	0.9409

نتایج نشان می‌دهد که شبکه با ضریب تعیین (R^2) بیش از ۹۴٪ روی داده تست، عملکرد بسیار خوبی دارد. این مقدار بالای R^2 نشان‌دهنده توانایی شبکه در یادگیری دینامیک غیرخطی سیستم است. همچنین مقدار RMSE پایین بیانگر خطای کم پیش‌بینی در مقایسه با دامنه تغییرات خروجی سیستم می‌باشد.

نمودار نشان می‌دهد پیش‌بینی‌های شبکه به خوبی روند خروجی واقعی را دنبال می‌کنند. خطاها عمدتاً در نقاط اوج و فرود سیگنال رخ داده‌اند که طبیعی است.



شکل ۴: مقایسه خروجی واقعی و پیش‌بینی شده توسط شبکه RBFNN


تأثیر تعداد نوروهای مخفی:

جدول ۱۸: تأثیر تعداد نوروهای مخفی (K) بر عملکرد شبکه

Test RMSE	Train RMSE	Test R^2	Train R^2	K
17.6028	12.1599	0.2510	0.2118	5
6.3056	5.0362	0.9039	0.8648	10
5.5516	4.4321	0.9255	0.8953	15
5.1302	3.9328	0.9364	0.9176	20
4.9440	3.7531	0.9409	0.9249	25
4.8452	3.5638	0.9433	0.9323	30
4.0143	3.0106	0.9610	0.9517	40
3.4413	2.5804	0.9714	0.9645	50

نمودار سمت چپ نشان می‌دهد R^2 با افزایش K به سرعت افزایش یافته و سپس به تدریج اشباع می‌شود. نمودار سمت راست کاهش RMSE را با افزایش تعداد نوروها نشان می‌دهد.

تحلیل نتایج:



شکل ۵: تأثیر تعداد نورون‌های مخفی بر معیارهای R^2 و RMSE

- با افزایش تعداد نورون‌ها، دقت شبکه افزایش می‌یابد
 - با ۵ نورون، شبکه قادر به یادگیری مناسب نیست ($R^2 = ۰.۲۵$)
 - از ۱۵ نورون به بالا، R^2 بیش از ۰.۹ است
 - با ۵۰ نورون، بهترین عملکرد حاصل می‌شود ($R^2 = ۰.۹۷۱۴$)
 - نکته مهم: R^2 تست بیشتر از R^2 آموزش است که نشان‌دهنده تعمیم‌پذیری خوب شبکه است
- تحلیل نتایج: با $K = 5$ نورون، شبکه ظرفیت کافی برای یادگیری رفتار غیرخطی پیچیده سیستم Ball-Beam را ندارد (کم‌برازش). این مانند تلاش برای تقریب یک منحنی پیچیده با فقط ۵ تابع گوسی است. با افزایش K ، شبکه می‌تواند ویژگی‌های محلی بیشتری را پوشش دهد. استفاده از K-Means برای انتخاب مراکز تضمین می‌کند که نورون‌ها در نقاط مهم فضای ورودی قرار گیرند، نه تصادفی.



۳.۱.۶ بخش سوم: آموزش از طریق حداقل مربعات خطی (LLS)

بند ۱.۳.۱ - ساخت ماتریس Φ و آموزش با LLS:

با ثابت بودن مراکز و عرض‌ها، خروجی RBFNN یک ترکیب خطی از فعال‌سازهای RBF است. برای محاسبه وزن‌های بهینه از روش LLS استفاده می‌کنیم:

$$Y = \Phi\alpha \Rightarrow \alpha = (\Phi^T\Phi)^{-1}\Phi^TY \quad (57)$$

که در آن $\Phi_{ij} = \phi_j(x_i)$ ماتریس طراحی است.

K مرکز به صورت تصادفی از مجموعه آموزش انتخاب شده و تمام عرض‌ها روی یک مقدار ثابت (میانگین فاصله بین مراکز) تنظیم شده است.

جدول ۱۹: نتایج آموزش اولیه با $K = 25$ و $\sigma = 6.90$

معیار	آموزش	تست
RMSE	13.40	20.22
R^2	0.043	0.012

R^2 بسیار پایین (۰.۰۱٪) نشان می‌دهد مدل تقریباً هیچ چیزی یاد نگرفته است. این نتیجه ضعیف به دلیل انتخاب تصادفی مراکز است که ممکن است در نقاط نامناسبی از فضای ورودی قرار گیرند.
بند ۱.۳.۲ - نمودار خروجی واقعی و پیش‌بینی شده (آموزش):
بند ۱.۳.۳ - نمودار خروجی واقعی و پیش‌بینی شده (تست):

نمودار نشان می‌دهد پیش‌بینی‌ها انحراف زیادی از مقادیر واقعی دارند. خط پیش‌بینی شده تقریباً افقی است که نشان‌دهنده عدم یادگیری الگوی داده توسط مدل است.


تحلیل خطا: بیشترین خطا در نقاطی رخ داده است که خروجی سیستم مقادیر حدی (بسیار بزرگ یا بسیار کوچک) دارد. این به دلیل آن است که مراکز تصادفی ممکن است پوشش مناسبی از فضای ورودی نداشته باشند.

تحلیل: توجه کنید که $R^2 = 0.01$ به معنای عدم توانایی مدل در یادگیری است. این نتیجه «بد» عمدی است و نشان می‌دهد چرا انتخاب تصادفی مراکز روش مناسبی نیست. مراکز تصادفی ممکن است در نقاطی قرار گیرند که داده‌ای وجود ندارد یا توزیع مناسبی نداشته باشند. مقایسه کنید: همین $K = 25$ با K-Means در بخش قبل $R^2 = 0.94$ داد!

بند ۱.۳.۴ - مقایسه سرعت LLS با Backpropagation:

آموزش با LLS بسیار سریع‌تر از Backpropagation است زیرا:

- LLS مسئله بهینه‌سازی را در یک مرحله با حل تحلیلی انجام می‌دهد
- Backpropagation نیاز به صدها یا هزاران تکرار (epoch) دارد
- LLS نیازی به تنظیم نرخ یادگیری ندارد
- Backpropagation ممکن است در مینیم‌های محلی گیر کند



شکل ۶: مقایسه خروجی واقعی و پیش‌بینی شده برای داده‌های آموزش و تست


بند ۱.۳.۵ - تأثیر تعداد مراکز (K):

جدول ۲۰: تأثیر تعداد مراکز بر عملکرد (با σ ثابت)

Test R^2	Test RMSE	Train RMSE	K
0.002	20.32	13.58	10
0.011	20.23	13.43	20
0.036	19.97	13.13	50
0.042	19.91	13.04	100
0.052	19.80	12.96	200

بهترین مقدار K : ۲۰۰ (با کمترین RMSE تست)

با افزایش تعداد مراکز، شبکه قادر به پوشش بهتر فضای ورودی می‌شود. البته افزایش بیش از حد K می‌تواند منجر به بیش‌برازش شود، اما در اینجا با $K = 200$ هنوز به این مشکل نرسیده‌ایم. نمودار نشان می‌دهد با افزایش K ، RMSE کاهش می‌یابد اما این کاهش بسیار کند است. حتی با $K = 200$ ، R^2 فقط ۵٪ است که نشان می‌دهد انتخاب تصادفی مراکز روش مناسبی نیست.



شکل ۷: تأثیر تعداد مراکز (K) بر RMSE

بند ۱.۳.۶ - کم‌برازش و بیش‌برازش مرتبط با K :

- K خیلی کوچک (کم‌برازش): تعداد نورون‌ها برای پوشش پیچیدگی تابع کافی نیست. مدل خیلی ساده است و هم خطای آموزش و هم خطای تست بالاست.
- K خیلی بزرگ (بیش‌برازش): مدل نویز داده آموزش را حفظ می‌کند. خطای آموزش کم ولی خطای تست افزایش می‌یابد.




بند ۱.۳.۷ - تأثیر عرض (σ):

جدول ۲۱: تأثیر عرض بر عملکرد (با $K = 200$)

Test R^2	Test RMSE	Train RMSE	σ
0.049	19.84	13.11	0.5
0.072	19.59	12.89	1.0
0.064	19.68	12.88	5.0
0.052	19.80	12.96	7.0
0.541	13.77	10.16	10.0

بهترین مقدار σ : ۱۰ (با $R^2 = ۵۴.۰$)

عرض σ بزرگ‌تر باعث می‌شود هر نورون ناحیه وسیع‌تری را پوشش دهد و همپوشانی بین نورون‌ها افزایش یابد. این همپوشانی برای درونیابی صاف بین نقاط داده ضروری است.




شکل ۸: تأثیر عرض (σ) بر RMSE تست

نمودار نشان می‌دهد $\sigma = 10$ بهترین عملکرد را دارد. با σ های کوچک، نورون‌ها ناحیه بسیار محدودی را پوشش می‌دهند و با σ های بزرگ‌تر از ۱۰، همپوشانی بیش از حد می‌شود.
بند ۱.۳.۸ - تأثیر σ بر تعمیم‌پذیری:

• σ خیلی کوچک: هر نورون فقط به ناحیه بسیار کوچکی پاسخ می‌دهد. مدل قادر به درونیابی بین نقاط آموزش نیست و تعمیم‌پذیری ضعیف است.



- σ خیلی بزرگ: همه نوروها خروجی مشابه می‌دهند و اطلاعات محلی از دست می‌رود. مدل خیلی صاف می‌شود و نمی‌تواند جزئیات را یاد بگیرد.



شکل ۹: خروجی بهترین مدل ($\sigma = 10$, $K = 200$) روی داده تست

نتایج بهترین مدل:

- تعداد مراکز: $K = 200$

- عرض: $\sigma = 10$

- RMSE تست: 13.77

- R^2 تست: 0.541

بند ۱.۳.۹ - چالش‌های انتخاب بهترین ساختار:

۱. وابستگی متقابل: K و σ به هم وابسته‌اند؛ بهینه بودن یکی به مقدار دیگری بستگی دارد.
۲. تصادفی بودن مراکز: انتخاب تصادفی مراکز باعث می‌شود نتایج در هر اجرا متفاوت باشد.
۳. هزینه محاسباتی: بررسی تمام ترکیبات K و σ زمان‌بر است.
۴. عدم وجود قانون کلی: مقادیر بهینه به دیتاست و مسئله خاص بستگی دارد.
۵. مصالحه: K بزرگ‌تر دقت بیشتر ولی خطر بیش‌برازش دارد؛ σ کوچک‌تر دقت محلی ولی تعمیم‌پذیری ضعیف دارد.



۴.۱.۶ بخش چهارم: تلاش برای حل چالش‌ها با L2 Regularization

بند ۱.۴.۱ - پیاده‌سازی RBFNN با L2 Regularization

وقتی K بسیار بزرگ باشد، ممکن است مشکل در تعمیم‌پذیری رخ دهد. یکی از روش‌های حل این مشکل، استفاده از L2 Regularization است. در این روش، رابطه بهینه‌سازی به صورت زیر تغییر می‌کند:


$$(\Phi^T \Phi + \lambda I) \alpha = \Phi^T Y \quad (58)$$

شبکه با $K = 200$ و $\sigma = 10$ و مقادیر مختلف λ آموزش داده شد:

جدول ۲۲: تأثیر ضریب رگولاریزاسیون (λ) بر عملکرد


λ	Train RMSE	Test RMSE	Test R ²
0	13.20	20.07	0.026
0.001	13.29	20.16	0.018
0.01	13.30	20.16	0.017
0.1	13.31	20.17	0.017
1	13.32	20.17	0.017
10	13.42	20.23	0.011

نتایج نشان می‌دهد با افزایش λ ، عملکرد کاهش می‌یابد. این به دلیل آن است که مدل با مراکز تصادفی از قبل دچار کم‌برازش است و رگولاریزاسیون اضافی فقط مشکل را بدتر می‌کند.



شکل ۱۰: تأثیر ضریب رگولاریزاسیون (λ) بر RMSE و R²

مقایسه با و بدون رگولاریزاسیون:



شکل ۱۱: مقایسه خروجی شبکه با و بدون L2 Regularization

بند ۱.۴.۲ - نقش پارامتر λ :

پارامتر λ ضریب رگولاریزاسیون است که قدرت جریمه روی بزرگی وزن‌ها را کنترل می‌کند. اثر λ خیلی کوچک (نزدیک صفر):

- تأثیر رگولاریزاسیون ناچیز است
- مدل همچنان ممکن است دچار بیش‌برازش شود
- وزن‌ها می‌توانند مقادیر بزرگ بگیرند
- اثر λ خیلی بزرگ:

- رگولاریزاسیون بیش از حد اعمال می‌شود
- وزن‌ها به سمت صفر فشرده می‌شوند
- مدل خیلی ساده شده و دچار کم‌برازش می‌شود
- شبکه توانایی یادگیری الگوهای پیچیده را از دست می‌دهد

λ بهینه: تعادل بین برازش داده‌ها و جلوگیری از بیش‌برازش را برقرار می‌کند. معمولاً با اعتبارسنجی متقاطع (Cross-Validation) انتخاب می‌شود.

نتیجه‌گیری: نتایج نشان می‌دهد $\lambda = 0$ بهترین است، یعنی رگولاریزاسیون کمکی نکرد. این کاملاً منطقی است! مدل ما با مراکز تصادفی دچار کم‌برازش (underfitting) است، $(R^2=0.03)$ نه بیش‌برازش. رگولاریزاسیون L_2 برای کاهش بیش‌برازش طراحی شده است، نه کم‌برازش. وقتی مدل از قبل ضعیف است، اضافه کردن جریمه روی وزن‌ها فقط آن را ضعیف‌تر می‌کند.




۵.۱.۶ بخش پنجم: استفاده از K-Means برای انتخاب مراکز

بند ۱.۵.۱ - مقایسه K-Means با انتخاب تصادفی:
به جای انتخاب تصادفی مراکز، از الگوریتم K-Means برای یافتن K مرکز استفاده شد.

جدول ۲۳: مقایسه K-Means و انتخاب تصادفی ($K = 50$)

روش	Test RMSE	Test R^2
مراکز K-Means	4.71	0.946
مراکز تصادفی	5.27	0.933

استفاده از K-Means باعث کاهش ۱۱٪ در RMSE و افزایش ۴٪.۱ در R^2 شده است. این بهبود به دلیل توزیع بهینه مراکز در فضای ورودی است که پوشش بهتری از داده‌ها فراهم می‌کند.



شکل ۱۲: مقایسه خروجی با مراکز K-Means و تصادفی

بند ۱.۵.۲ - استراتژی Nearest-Neighbor برای محاسبه σ :
تابعی نوشته شد که σ هر نورون را بر اساس میانگین فاصله تا p نزدیک‌ترین مرکز محاسبه می‌کند ($p = 2$).

جدول ۲۴: نتایج با σ متغیر (NN با $p = 2$)

معیار	آموزش	تست
RMSE	2.54	3.43
R^2	-	0.972


با استفاده از σ متغیر، R^2 به ۹۷٪.۲ رسیده که بهترین نتیجه تا این بخش است. این روش به هر نورون اجازه می‌دهد متناسب با چگالی محلی داده‌ها عرض مناسب داشته باشد.
مقایسه σ ثابت و σ متغیر:

• σ ثابت: RMSE تست = 4.71

• σ متغیر (NN): RMSE تست = 3.43



تحلیل نتایج: K-Means با $RMSE=71.4$ بهتر از Random با $RMSE=27.5$ عمل می‌کند. همچنین σ متغیر با روش Nearest-Neighbor بهترین عملکرد را با $RMSE=43.3$ دارد. در نواحی متراکم فضای ورودی، σ کوچک‌تر می‌شود و در نواحی پراکنده، σ بزرگ‌تر می‌شود تا پوشش بهتری داشته باشد.



شکل ۱۳: مقایسه σ ثابت و σ متغیر (Nearest-Neighbor)

بند ۱.۵.۳ - چرا K-Means بهتر از انتخاب تصادفی است؟

از نظر تنوری، K-Means روش بهتری برای انتخاب مراکز RBF است زیرا:

۱. پوشش بهتر فضای ورودی: K-Means مراکز را در نقاطی قرار می‌دهد که چگالی داده بیشتر است.
۲. کاهش همپوشانی: مراکز به صورت یکنواخت در فضا توزیع می‌شوند و همپوشانی کمتری دارند.
۳. نمایندگی بهتر داده: هر مرکز نماینده یک خوشه از داده‌هاست، نه یک نقطه تصادفی.
۴. بهینه‌سازی موقعیت: K-Means به صورت تکراری موقعیت مراکز را بهینه می‌کند.
۵. قابلیت تکرار: نتایج قابل تکرار هستند (برخلاف انتخاب تصادفی).



۲.۶ قسمت دوم: شبکه RBFNN تطبیقی با الهام از M-RAN

۱.۲.۶ بخش اول: یادگیری ترتیبی و معیار رشد

بند ۲.۱.۱ - تابع معیار رشد:

تابعی نوشته شد که یک نمونه جدید (x_n, y_n) ، مقدار پیش‌بینی، و آستانه‌های ε و e_{min} را دریافت می‌کند و تعیین می‌کند آیا نورون جدید باید اضافه شود یا خیر. معیارهای رشد شبکه:

$$1. \text{ تازگی (Novelty): } \|x_n - \mu_n\| > \varepsilon$$

ورودی x_n از تمام مراکز موجود دور باشد.

$$2. \text{ خطا (Error): } |y_n - f(x_n)| > e_{min}$$

خطای پیش‌بینی بزرگ باشد.

نورون جدید فقط زمانی اضافه می‌شود که هر دو معیار برقرار باشند.

بند ۲.۱.۲ - چرا هر دو معیار ضروری هستند؟

- فقط معیار خطا: نورون‌های زیادی در مناطقی که قبلاً پوشش داده شده اضافه می‌شوند $\Rightarrow$ افزونگی.
- فقط معیار تازگی: نورون‌ها در مناطق کم‌اهمیت اضافه می‌شوند حتی اگر مدل دقت کافی داشته باشد.
- افزایش ε : نورون‌های کمتری اضافه می‌شوند $\Rightarrow$ مدل ساده‌تر اما ممکن است underfit شود.
- کاهش ε : نورون‌های بیشتری اضافه می‌شوند $\Rightarrow$ مدل پیچیده‌تر اما ممکن است overfit شود.

۲.۲.۶ بخش دوم: پیاده‌سازی RBFNN تطبیقی با هرس

بند ۲.۲.۱ - پیاده‌سازی کلاس AdaptiveRBFNN:

شبکه با صفر نورون شروع می‌شود و با پردازش ترتیبی داده‌ها رشد می‌کند. استراتژی هرس:

$$\bullet \text{ مشارکت خروجی: } o_k^n = \alpha_k \times \phi_k(x_n)$$

$$\bullet \text{ نرمال‌سازی: } r_k^n = \frac{|o_k^n|}{\max_k(|o_k^n|)}$$

$$\bullet \text{ اگر } r_k^n < \delta \text{ برای } M \text{ مشاهده متوالی } \Rightarrow \text{ حذف نورون } k$$

بند ۲.۲.۲ - آموزش و ارزیابی:

نتایج نشان می‌دهد تغییر e_{min} تأثیر کمی بر RMSE نهایی دارد اما تعداد نورون‌ها را تغییر می‌دهد. با $e_{min} = 0.20$ شبکه فشرده‌تری با ۴۰ نورون به دست می‌آید که همان دقت را دارد.


بهترین پیکربندی: $\varepsilon = 0.5$ ، $e_{min} = 0.15$

تعداد نورون نهایی: 47، Test RMSE: 4.86، R^2 : 0.943




جدول ۲۵: جستجوی هایپرپارامتر ($M = 60, \delta = 0.1, \eta = 0.05, \kappa = 0.8$)

Test RMSE	نورون‌ها	ε	e_{min}
4.87	48	0.5	0.05
4.87	49	0.5	0.10
4.86	47	0.5	0.15
4.86	40	0.5	0.20



شکل ۱۴: نتایج RBFNN تطبیقی روی داده‌های تست

این نتایج نشان می‌دهد که الگوریتم تطبیقی توانسته با تعداد محدودی نورون به دقت قابل قبولی برسد. رشد تدریجی شبکه و مکانیزم هرس باعث شده ساختار نهایی بهینه باشد.
بند ۲.۲.۳ - نمودار تغییر تعداد نورون‌ها:



شکل ۱۵: تغییر تعداد نورون‌ها در طول آموزش

نمودار نشان می‌دهد شبکه در ابتدای آموزش به سرعت رشد کرده و سپس با فعال شدن مکانیزم هرس، تعداد نورون‌ها تثبیت شده است. این رفتار نشان‌دهنده عملکرد صحیح معیارهای رشد و هرس است.




بند ۲.۲.۴ - مقایسه RBFNN تطبیقی و ایستا:

جدول ۲۶: مقایسه مدل‌های مختلف

Test RMSE	نورون‌ها	مدل
4.86	47	Adaptive RBFNN (M-RAN)
3.43	50	Static RBFNN (K-Means+NN)
3.25	47	Static RBFNN (K=47)

روش Static با K-Means و NN Sigma بهترین عملکرد را با $RMSE=43.3$ دارد. روش تطبیقی با $RMSE=86.4$ عملکرد ضعیف‌تری دارد اما مزیت آن یادگیری آنلاین بدون نیاز به ذخیره کل داده‌هاست.



شکل ۱۶: مقایسه RBFNN تطبیقی و ایستا

بند ۲.۲.۵ - بحث: مزایا و معایب M-RAN

مزایا:

- تعیین خودکار توپولوژی شبکه (بدون نیاز به انتخاب K)
- یادگیری آنلاین و افزایشی
- حذف نورون‌های زائد با مکانیزم هرس
- مناسب برای کاربردهای real-time

معایب:

- دقت کمتر نسبت به روش‌های ایستا (به دلیل آموزش آنلاین)
- حساسیت به ترتیب داده‌ها
- تنظیم هایپرپارامترهای متعدد ($M, \delta, \eta, \kappa, e_{min}, \varepsilon$)



نتیجه‌گیری: در این پیاده‌سازی، Static RBFNN با K-Means و NN Sigma عملکرد بهتری داشت ($RMSE=3.43$ در مقابل 4.86). این نتیجه به دلیل آموزش batch و بهینه‌سازی مراکز است. با این حال، M-RAN مزیت مهمی در کاربردهای دنیای واقعی دارد: توانایی یادگیری آنلاین و تطبیق با داده‌های جدید بدون آموزش مجدد کامل. مقایسه: روش Static از تمام داده‌های آموزش به صورت همزمان استفاده می‌کند و با K-Means مراکز بهینه را پیدا می‌کند، در حالی که M-RAN فقط یک نمونه در هر لحظه می‌بیند. مزیت M-RAN در کاربردهایی است که داده به صورت جریانی می‌آید، مثل سیستم‌های کنترل real-time.




۷ سوال هفتم: SVM خطی و مطالعه پارامتر C

در این سوال، یک ماشین بردار پشتیبان خطی برای مسئله تشخیص سرطان سینه پیاده‌سازی و تأثیر پارامتر C بر عملکرد مدل بررسی می‌شود. پارامتر C کنترل‌کننده توازن بین بیشینه‌سازی حاشیه و کمینه‌سازی خطای طبقه‌بندی است.

۱.۷ قسمت الف: آماده‌سازی داده

مجموعه داده: Breast Cancer Wisconsin (Diagnostic)

- تعداد نمونه: 569
- تعداد ویژگی: 30
- کلاس‌ها: Malignant (بدخیم) و Benign (خوش‌خیم)
- تقسیم‌بندی داده (random_state = 53):
 - آموزش: 341 نمونه (60%)
 - اعتبارسنجی: 114 نمونه (20%)
 - تست: 114 نمونه (20%)



شکل ۱۷: نمایش PCA دوبعدی داده‌های آموزش

نمودار PCA نشان می‌دهد که دو کلاس در فضای کاهش‌یافته به خوبی از هم جدا هستند. این جداپذیری اولیه نشان‌دهنده موفقیت احتمالی یک طبقه‌بند خطی برای این مسئله است.



۲.۷ قسمت ب: آموزش و گزارش حاشیه

مدل $SVC(kernel='linear', C=1)$ آموزش داده شد. بردار وزن با رابطه زیر محاسبه می‌شود:

$$w = \sum_i \alpha_i y_i x_i$$

جدول ۲۷: نتایج آموزش با $C = 1$

مقدار	معیار
26	تعداد Support Vectors
16.15	$\ w\ $
0.062	حاشیه $= 1/\ w\ $

تعداد ۲۶ بردار پشتیبان نشان می‌دهد که حدود ۶٪.۷ از داده‌های آموزش در تعیین مرز تصمیم نقش دارند. حاشیه ۰.۰۶۲۰ نسبتاً کوچک است که نشان‌دهنده تفکیک خوب دو کلاس در فضای اصلی است.

جدول ۲۸: شاخص‌های عملکرد ($C = 1$)

Test	Validation	شاخص
0.991	0.965	Accuracy
1.000	-	Precision
0.986	-	Recall
0.993	-	F1
1.000	-	ROC-AUC

دقت ۹۹٪ و $F1$ Score برابر ۹۹٪.۳ نشان‌دهنده عملکرد بسیار عالی مدل است. $Precision = ۱.۰۰$ یعنی هیچ تشخیص مثبت کاذبی وجود ندارد و $Recall = ۹۸۶.۰$ یعنی تنها ۴٪.۱ از موارد بدخیم تشخیص داده نشده‌اند.

۳.۷ قسمت ج: مطالعه پارامتر C

جدول ۲۹: تأثیر C بر عملکرد مدل


Test Acc	Val Acc	حاشیه	SV#	C
0.982	0.947	1.565	82	0.01
0.991	0.956	0.728	44	0.1
0.991	0.965	0.390	26	1
0.965	0.956	0.128	24	10
0.974	0.939	0.062	21	100



با افزایش C از ۰.۱ به ۱.۰، تعداد بردارهای پشتیبان از ۸۲ به ۲۱ کاهش یافته و حاشیه از ۵۶۵.۱ به ۰.۶۲۰ کوچک شده است. بهترین عملکرد روی داده اعتبارسنجی با $C = 1$ به دست آمده که توازن مناسبی بین حاشیه و دقت ایجاد می‌کند. تحلیل بایاس/واریانس:

- C کوچک: حاشیه بزرگ‌تر، SV بیشتر، بایاس بالا، مدل ساده‌تر (underfitting).
- C بزرگ: حاشیه کوچک‌تر، SV کمتر، واریانس بالا، مدل پیچیده‌تر (overfitting).
- C بهینه ($C = 1$): بهترین تعادل بین بایاس و واریانس.

پارامتر C جریمه خطای طبقه‌بندی را کنترل می‌کند. با C کوچک، SVM اجازه می‌دهد برخی نمونه‌ها در سمت اشتباه حاشیه قرار گیرند تا حاشیه بزرگ‌تری داشته باشد. با C بزرگ، SVM سعی می‌کند همه نمونه‌ها را درست طبقه‌بندی کند. کاهش تعداد SVها با افزایش C نشان می‌دهد مدل به نقاط خاص‌تری وابسته می‌شود و تعمیم‌پذیری آن کاهش می‌یابد.



شکل ۱۸: تحلیل تأثیر پارامتر C


نمودارها رابطه معکوس بین تعداد بردارهای پشتیبان و C را نشان می‌دهند. همچنین حاشیه با افزایش C به صورت نمایی کاهش می‌یابد. دقت مدل در C های میانی بیشینه است.



۴.۷ قسمت د: منحنی‌های ارزیابی

بهترین C بر اساس Validation: $C = 1$

انتخاب $C = 1$ بر اساس بهترین عملکرد روی مجموعه اعتبارسنجی انجام شده است. این مقدار توازن مناسبی بین بایاس و واریانس ایجاد می‌کند و منجر به بهترین تعمیم‌پذیری می‌شود.



شکل ۱۹: منحنی‌های ROC و Precision-Recall برای $C = 1$

تفسیر:

- منحنی ROC: $AUC = 1.00$ نشان‌دهنده جداسازی کامل دو کلاس است. این منحنی نرخ مثبت واقعی را در برابر نرخ مثبت کاذب در آستانه‌های مختلف نشان می‌دهد.
- منحنی Precision-Recall: $AUC = 1.00$ نشان می‌دهد مدل در تمام آستانه‌ها دقت و بازیابی بالایی دارد. این منحنی برای داده‌های نامتوازن بسیار مفید است.
- عملکرد عالی مدل به دلیل جدایندگی خوب داده‌ها در فضای ۳۰ بعدی است.

$AUC = 0.1$ نشان می‌دهد مدل تمام نمونه‌های مثبت را بالاتر از تمام نمونه‌های منفی رتبه‌بندی کرده است. ویژگی‌های استخراج شده از تصاویر سلولی تفاوت قابل توجهی بین تومورهای خوش خیم و بدخیم دارند. در فضای ۳۰ بعدی، این دو کلاس تقریباً به صورت خطی جدایند هستند و نمودار PCA دوبعدی نیز این جدایندگی را تأیید می‌کند.